



中国研究生创新实践系列大赛
“华为杯”第二十三届中国研究生
数学建模竞赛

学 校 华侨大学

参赛队号 20260079591

队员姓名	1. 梅芷涵
	2. 罗加印
	3. 刘玫均

中国研究生创新实践系列大赛

“华为杯”第二十三届中国研究生

数学建模竞赛

题 目： 算力约束下提升大语言模型能力的资源配置建模

摘 要：

本文建立“数据度量—广义标度律—约束优化—能力预测”的递进模型，分源估计参数，以可检验假设衔接各附件。

针对问题一，将 22 项指标按正向、逆向、饱和型、适中型统一方向，分五个语义块以稳定 CRITIC 赋权；以块间极差定义质量冲突并用 Huber 稳健估计消解。冲突率为 3.17%，其中 93.4% 以“结构充分”为短板，成因是形式指标与内容指标测量对象不同，该结论在扩展集上同样成立。七域质量以 C4 (0.619) 最高、GitHub (0.430) 最低。以二阶 Scheffé–Ridge 混料模型刻画 17 域配比与 Loss，在 1M、60M、1B 检验集上 Spearman 系数为 0.858、0.870、0.850，领域间以互补为主。

针对问题二，经留一规模验证选定可分幂律 ($\text{RMSE } 1.5 \times 10^{-4}$)，经成块交叉验证选定加性质量惩罚。发现配比效应的绝对强度随规模下降 69%，但其占可约损失的比例 $\theta \approx 0.085$ 在三个数量级上不变，据此提出广义标度律 $L = E + [An^{-\alpha} + Bd^{-\beta} + c_Q(1 - Q)^{\nu_Q}]e^{\theta R(p)}$ ，它在 $Q = 1$ 时退化为经典形式且恒有 $L > E$ 。证明了质量—规模替代的充要条件并给出闭式解：质量提高 0.1 等价于参数增加 37.3% 或数据增加 56.9%。

针对问题三，证明配比与规模—质量决策可分离，利用 Loss 对 D 的单调性解析降维后多起点求解。临界上下文长度为 $6/\eta = 30000$ 。4096 上下文、指数成本下， 10^{19} 、 10^{22} 、 10^{24} FLOPs 的最优 (N^*, D^*, Q^*) 为 (0.26B, 4.8B, 0.67)、(5.45B, 244B, 1.0)、(39.6B, 3654B, 1.0)，采用近优配比可使可约损失再降 17.6%。以 KKT 活跃约束集合的变化定义结构性转移，识别出“规模优先—质量与规模竞争—质量饱和后规模主导”三阶段。

针对问题四，以六项官方归一化得分均值度量能力，限定开放权重的 pretrained 模型、按提交日期计时，C8 逐任务重算 BBH 复现率 97.2%。建立单调 Loss–Benchmark 桥接与 0.90 分位动力学前沿，Shapley 分解显示 2024-06 至 2025-01 前沿提升 4.62 分，规模扩张贡献约 100%。算力增速保留 100%、50%、25% 时，24 个月后能力前沿中心值为 77.2、65.7、59.2 分。

关键词： 广义标度律 数据质量 混料模型 KKT 条件 结构性转移 分位数前沿

目录

1	问题重述	3
1.1	问题背景	4
1.2	需要解决的问题	4
2	问题分析	5
2.1	总体思路	6
2.2	问题一的分析	6
2.3	问题二的分析	7
2.4	问题三的分析	7
2.5	问题四的分析	7
3	模型假设与符号说明	7
3.1	模型假设	8
3.2	符号说明	8
4	问题一：数据质量评价、冲突消解与领域配比模型	9
4.1	数据预处理	10
4.2	质量评价模型	11
4.3	质量冲突的识别与消解	13
4.4	领域质量评价与抽样集对照	14
4.5	领域配比—Loss 响应模型	17
4.6	配比模型的求解结果	18
4.7	问题一小结	22
5	问题二：跨维度数据融合与广义标度律	24
5.1	建模思路与可检验假设	25
5.2	经典标度律	25
5.3	质量修正项	27
5.4	配比修正项与尺度不变性检验	29
5.5	广义标度律	30
5.6	边际效用、弹性与替代条件	32

5.7	模型检验	34
5.8	问题二小结	35
6	问题三：算力约束下的资源联合优化与结构性转移	36
6.1	优化模型的建立	37
6.2	上下文长度的临界值与可行取值	38
6.3	模型求解	38
6.4	求解结果	40
6.5	模型检验与敏感性分析	45
6.6	问题三小结	46
7	问题四：技术演进分析与能力前沿预测	47
7.1	口径界定与数据准备	48
7.2	Loss-Benchmark 桥接模型	49
7.3	能力前沿的动力学模型	52
7.4	规模扩张与非规模技术进步的贡献分解	53
7.5	算力放缓情景下的能力前沿预测	54
7.6	模型检验	56
7.7	问题四小结	57
8	模型的评价、改进与推广	57
8.1	模型的优点	58
8.2	模型的不足	58
8.3	模型的改进	59
8.4	模型的推广	59
	参考文献	59
	附录A AI 工具使用说明	62
	附录B 支撑材料与程序清单	63

1 问题重述

1.1 问题背景

以大语言模型 (LLM) 为代表的人工智能技术正沿着“扩大规模”的路径快速演进。经典标度律 [1, 2] 表明, 验证集交叉熵损失随参数量 N 与训练 Token 数 D 按幂律下降, 训练算力近似为 $C \approx 6ND$ 。然而, 单纯扩大规模正面临两重约束: 一是算力增长趋缓, 二是可用高质量语料日益稀缺, 即所谓“数据墙” [3, 4]。与此同时, 数据质量与领域配比对模型能力的作用日益凸显: 仅 80 亿参数的 OpenScholar-8B 在引文准确率等任务上优于 GPT-4o [5], 以“教科书级”数据训练的小模型同样表现出超越规模的能力 [6]。

提升质量、扩大规模、延长上下文都要消耗算力, 而调整领域配比虽不增加总开销, 却改变算力在各领域间的分配效果。因此, 在有限算力下如何在参数规模 N 、数据规模 D 、数据质量 Q 、领域配比 $\mathbf{p}$ 与上下文长度 L_{ctx} 之间取舍, 是一个典型的多资源约束优化问题。本题要求利用真实公开数据与已标注的半合成补充数据, 刻画上述因素与 Loss 的定量关系, 求解算力约束下的最优资源配置, 并据此预测开源大模型的能力前沿。

1.2 需要解决的问题

四个问题构成“数据属性—损失规律—资源决策—能力前沿”的递进主线, 前一问的输出是后一问的输入。

问题一：数据质量评价、质量冲突消解与领域配比建模。(1) 对附件 A1–A3 的 22 项质量指标统一方向并预处理, 建立综合评价模型, 给出样本级与领域级质量评分 Q , 说明聚合方式, 并将全量结果与抽样集 A1 对照; (2) 定义不同指标对同一文本评价显著不一致的“质量冲突”, 分析成因并建立消解规则, 在抽样集上分析、在扩展集上检验; (3) 利用 A4–A15 建立 17 域配比 $\mathbf{p}$ 与交叉熵损失的定量关系, 处理单纯形约束, 在检验集 A6–A11 上验证, 并用外推表 A12–A15 讨论外推稳健性。

问题二：跨维度数据融合与广义标度律。在经典标度律 $L = E + AN^{-\alpha} + BD^{-\beta}$ 基础上, 综合附件 A、B 建立同时包含 $N, D, Q, \mathbf{p}$ 的广义标度律, 提出统一两类实验的可检验假设; 完成参数估计、检验与验证 (B1 为主拟合, B2/B3、B4/B5 做族外与文献验证, B6–B8 为质量数据, B9/B10 讨论百亿参数以上外推); 分析各因素的边际效用与弹性、领域间的替代与互补关系, 并推导质量提升与规模扩大可相互替代的条件。

问题三：算力约束下的多维资源联合优化与结构性转移。总算力由基础训练 $6ND$ 、质量提升 $D[g(Q) - g(Q_0)]_+$ 与长文本注意力 ηNDL_{ctx} 三部分构成 ($\eta = 2 \times 10^{-4}$, L_{ctx} 依据 C7 外生给定)。在预算 C 下求解最优资源配置, 比较三类质量成本函数的影响; 给出注意力开销与训练开销相当的临界长度 $L_{\text{ctx}}^{\text{crit}} = 6/\eta$ 并做敏感性分析; 考察 $C = 10^{19}, 10^{22}, 10^{24}$ FLOPs 等不同量级预算下最优策略是否发生结构性转移, 给出其数学定义与识别方法。

问题四：技术演进分析与前沿预测。结合附件 C 建立动力学或因果推断模型，分离并量化规模扩张与非规模技术进步对能力提升的贡献占比；利用 Loss-Benchmark 桥接数据把前三问的 Loss 结论映射到下游能力并讨论映射误差；说明综合能力度量、开源筛选口径、模型类型与时间轴口径，在算力增长放缓情景下预测未来 12 或 24 个月开源大模型能力前沿并给出不确定性分析。

2 问题分析

2.1 总体思路

本题的核心是“把算力花在哪里”。四个问题分别对应一条完整决策链上的四个环节：**度量**（数据好不好、怎么配）→ **建模**（数据与规模如何共同决定 Loss）→ **决策**（预算约束下如何分配）→ **预测**（Loss 如何转化为能力、能力前沿走向何处）。附件 A、B、C 分别来自不同实验体系，Loss 的量纲与模型族并不相同，直接拼接回归会把“数据来源差异”误当作“资源效应”。因此本文坚持**分源估计**、**接口传递**的原则：每一问只用本问对应的附件估计参数，跨问题只传递含义明确的中间量（质量基线 Q_0 、参考配比 p_{ref} 、配比响应 $R(p)$ 、广义标度律参数、最优 Loss），并在接口处提出可检验的假设。总体技术路线如图 2.1 所示。




图 2.1 全文技术路线：四个问题的数据来源、模型方法、关键输出与检验关系

2.2 问题一的分析

问题一包含两条统计单位不同的任务。**质量评价**以文本为单位：22 项指标兼有连续统计量、分类概率与列表型评分，量纲不一、方向各异，且长度、句数等结构指标并非越大越好，需要先做“同向化 + 适中型效用”处理；指标间信息高度重叠（如三类相似度指标），直接等权会重复计权，因此采用**按语义分块、块内客观赋权、块间等权**的层次综合评价。当“内容好而形式差”一类矛盾出现在同一文本上时，简单平均会被单一极端维度拉偏，需要先用块间极差识别冲突，再用对离群块不敏感的 Huber 稳健估计消解。

配比建模以训练配方为单位：17 个领域份额满足单纯形约束 $\sum_i p_i = 1$ ，普通回归会出现完全共线。混料试验设计中的 Scheffé 多项式 [7, 8] 天然满足该约束，其二阶交互项还

能直接刻画“两个领域组合是否产生额外收益”。153 个特征相对 512 组训练配方偏多，需要 Ridge 正则化；模型在 1M、60M、1B 三个实测规模上检验，再用 10B、70B 估算表讨论外推。

2.3 问题二的分析

经典标度律只含 N, D 。本问要把质量 Q 与配比 p 纳入，但附件中不存在同时改变四个因素的联合实验：B1 只变 (N, D) ，B7 在固定 (N, D) 网格上变 Q ，附件 A 只变 p 。因此广义标度律必须采用**可分结构**，使每一项都能由一类数据单独识别，再通过可检验的假设拼合：(i) 质量项在 $Q = 1$ 时消失，模型退化为经典形式；(ii) 配比项以**相对可约损失**的形式作用，其强度不随规模变化——这一点可以在附件 A 的 1M、60M、1B 三个规模上直接检验。在此基础上，边际效用与弹性、质量—规模等价增幅都可以写成闭式，从而推导出“质量提升能否由规模扩张替代”的可计算条件。

2.4 问题三的分析

问题三是一个带非线性预算约束的连续优化问题。由于 Loss 关于 D 严格递减，最优解必然用尽预算，可由预算方程解析消去 D ，把三维问题降为 $(\log N, Q)$ 上的二维有界问题；若广义标度律中配比项为乘性结构，则最优 (N^*, D^*, Q^*) 与配比无关，配比可以与规模—质量决策**分离**求解。“结构性转移”需要严格定义：本文以 KKT 条件中活跃约束集合的改变定义主要转移（如质量投入从“不启动”到“启动”再到“饱和”），以配置弹性的断点定义次要转移，并用参数 bootstrap 检验转移的稳定性。上下文长度只改变单位 Token 的有效训练成本，注意力与训练开销之比 $\eta L_{\text{ctx}}/6$ 与预算无关，临界长度可解析给出。

2.5 问题四的分析

问题四从 Loss 尺度转向下游 Benchmark 能力。首先需要统一能力口径（六任务官方归一化均分）、开源口径（开放权重且可追溯）、模型类型（区分 pretrained 与 chat/finetuned）与时间轴（提交日期）。其次，“规模扩张”与“非规模技术进步”在历史数据中同时发生，需要在同一模型中同时控制训练算力与时间状态：本文以 0.90 条件分位刻画能力前沿，以局部线性趋势描述非规模状态的演进，再用两因素 Shapley 值把首末时点的前沿提升无序依赖地分解为两部分。最后，以 C6 的 Loss–Benchmark 配对建立单调桥接，把问题三的最优 Loss 映射为能力，并在算力增速保留 100%、50%、25% 三种情景下外推 12、24 个月的能力前沿，用分层 bootstrap 同时传播桥接、前沿与算力趋势三类不确定性。

3 模型假设与符号说明

3.1 模型假设

- (1) **分源可识别假设**。附件 A、B、C 的实验条件与 Loss 量纲不同，不把它们观测拼接为同一回归样本；各附件分别估计各自可识别的参数，跨附件只通过含义明确的中间量传递信息。
- (2) **质量指标单调可比假设**。22 项质量指标经同向化后，数值越大表示在该指标语义下质量越高；综合质量 Q 反映本指标体系下的相对质量，其尺度在 $[0, 1]$ 内可比较。
- (3) **广义标度律可分假设**。在观测支持域内，Loss 可以写成“不可约项 + 参数项 + 数据项 + 质量惩罚项”的可加形式，并且各项系数为正、各项随对应资源单调递减； $Q = 1$ 时质量惩罚项为零，模型退化为经典标度律。
- (4) **配比效应尺度不变假设**。领域配比通过乘性因子 $\exp[\theta R(\mathbf{p})]$ 作用于可约损失 $L - E$ ，系数 θ 不随模型规模改变。该假设可检验，第 5.4 节在 1M、60M、1B 三个规模上对其进行了检验。
- (5) **质量尺度锚定假设**。问题一的质量评分与附件 B 的质量字段在参考配比对应的质量 Q_{ref} 处对齐，二者以斜率 s_Q 线性对应（主情景 $s_Q = 1$ ，并以 0.5、1.5 做敏感性分析）。
- (6) **算力成本可加假设**。基础训练、质量提升与长上下文注意力三类开销按题设 FLOPs 公式相加，训练、质量处理与注意力计算使用同一 D ；上下文长度 L_{ctx} 由 C7 外生给定。
- (7) **能力前沿平滑演进假设**。开源 pretrained 模型的 0.90 分位能力前沿由训练算力和一个平滑演进的时间状态共同决定；时间状态吸收架构、数据工程、优化方法等非规模因素的综合作用。

3.2 符号说明

绝对参数量与 Token 数记为 N 和 D ；标度律中使用十亿尺度 $n = N/10^9$ 、 $d = D/10^9$ 。主要符号见表 3.1。

表 3.1 主要符号说明

符号	含义	单位/取值
u_{ij}	样本 i 在指标 j 上同向化后的效用	$[0, 1]$
B_{ib}	样本 i 在语义块 b 上的块评分	$[0, 1]$
K_i	样本 i 的块间极差（冲突强度）	$[0, 1]$
Q_i, q_d	样本级综合质量、领域级稳健质量	$[0, 1]$

表 3.1 主要符号说明 (续)

符号	含义	单位/取值
$\mathbf{p}$	17 个训练领域的配比向量, $p_i \geq 0, \sum_i p_i = 1$	单纯形
$\mathbf{p}_{\text{ref}}, \mathbf{p}^*$	训练配方的平均配比 (参考配比)、支持域内的近优配比	单纯形
$\hat{L}_k(\mathbf{p})$	第 k 个验证域的配比响应 (Scheffé–Ridge 预测)	交叉熵
$R(\mathbf{p})$	相对参考配比的标准化配比响应, $R(\mathbf{p}_{\text{ref}}) = 0$	无量纲
N, D	模型参数量、训练 Token 数	个
E	不可约损失	交叉熵
$A, \alpha; B, \beta$	参数项、数据项的系数与指数	正数
c_Q, ν_Q	质量惩罚项的系数与指数	正数
θ	配比效应系数 (相对可约损失)	正数
Q_0	基线质量, $Q_0 = \mathbf{p}_{\text{ref}}^\top \mathbf{q} = 0.5390$	$[0, 1]$
Q_A, Q_{eff}	质量处理后的决策质量、进入 Loss 的有效质量	$[0, 1]$
ϵ_x	Loss 对资源 x 的弹性, $\epsilon_x = -\partial \ln L / \partial \ln x$	无量纲
r_N, r_D	与质量提升 ΔQ 等效的参数量、数据量相对增幅	无量纲
C	总算力预算	FLOPs
$g(Q)$	单位 Token 的质量提升成本函数	FLOPs/Token
L_{ctx}, η	上下文长度、注意力开销系数 ($\eta = 2 \times 10^{-4}$)	Token, —
$\mathcal{A}(C)$	预算 C 下最优解的活跃约束集合	集合
S	六任务综合能力得分	$[0, 100]$
τ	能力前沿的条件分位水平 (主分析 $\tau = 0.90$)	—
κ	算力对数增速保留比例	$\{1, 0.5, 0.25\}$

4 问题一：数据质量评价、冲突消解与领域配比模型

问题一的求解分为两条链（图 4.1）：**质量链**以文本为单位，完成“指标同向化 → 分块赋权 → 冲突识别与稳健消解 → 领域聚合”；**配比链**以训练配方为单位，完成“单纯形建模 → 响应面选择 → 跨规模检验 → 支持域内寻优”。两条链在“领域质量是否解释配比收益”处汇合，并向问题二输出基线质量 Q_0 、参考配比 p_{ref} 与配比响应 $R(p)$ 。




图 4.1 问题一求解流程：质量评价链与配比建模链

4.1 数据预处理

各附件的统计单位与用途见表 4.1。检验集与外推表只在模型冻结后使用一次，不参与模型选择与调参。

表 4.1 问题一使用的数据及其用途

附件	规模	用途
A1 / A2 / A3	51230 / 17523 / 203752 条质量记录	质量评价、冲突分析；A1 为抽样集，A2(arXiv)、A3(GitHub) 为扩展集
A4 / A5	512 组配方 × 13 个验证域 Loss	配比响应面训练与五折交叉验证
A6-A11	1M、60M 各 256 组，1B 64 组	冻结模型后的独立检验
A12-A15	10B、70B 各 63 组（估算标签）	外推稳健性讨论
A16 / A18	领域映射指引、17 域原始文本样本	质量域到配比域的映射

去重。A1 与 A2、A3 分别有 1419 条 arXiv、10000 条 GitHub 记录重合。以“规范化领域名 + 样本 ID”联合去重，重合记录的质量字段逐一核对无冲突，最终得到 261086 条独立记录。少量非有限值（A1 中 18 条、A3 中 1 条）保留为缺失，评分时只用有效指标并在块内重新归一权重，不做均值插补。

单纯形闭合。配比表与 Loss 表按 index 一一配对。存储精度会带来微小的闭合误差，对第 r 组配方作非负截断与重新归一化：

$$p_{ri} = \frac{\max(a_{ri}, 0)}{\sum_{j=1}^{17} \max(a_{rj}, 0)}, \quad p_{ri} \geq 0, \quad \sum_{i=1}^{17} p_{ri} = 1, \quad (4.1)$$

修正后最大行和误差为 4.44×10^{-16} 。

4.2 质量评价模型

4.2.1 指标同向化

先把列表型与 logits 型指标压缩为标量：二分类 logits 取正类概率，六级分类 logits 取有序期望，QuRating[9] 的四个分量分别转换后取均值，得到题目要求的 22 项指标。为避免 GitHub 等大样本领域主导经验分布，对需要秩变换的指标 j 先在七个质量域内分别估计经验分布，再等权合成平衡参考分布

$$F_j^{\text{bal}}(x) = \frac{1}{7} \sum_{d=1}^7 F_{jd}(x), \quad (4.2)$$

并按其 0.5%、99.5% 分位截尾。根据指标语义，采用四类效用函数把所有指标统一为“越高越好”的 $u_{ij} \in [0, 1]$ ：

$$u_{ij} = \begin{cases} F_j^{\text{bal}}(x_{ij}), & \text{正向指标（如教育价值、流畅度），} \\ 1 - F_j^{\text{bal}}(x_{ij}), & \text{逆向指标（如广告含量、重复 } n\text{-gram 比例），} \\ \min\{F_j^{\text{bal}}(x_{ij})/0.95, 1\}, & \text{饱和型指标（词元熵、独特词比例），} \\ \exp[-(z_{ij} - m_j)^2/(2s_j^2)], & \text{适中型指标（文本长度、句数、平均词长），} \end{cases} \quad (4.3)$$

其中 $z_{ij} = \log(1 + \max\{x_{ij}, 0\})$ ，中心 m_j 与稳健尺度 s_j 在“高流畅、低广告、高整洁”的可信样本上按七域平衡方式估计。数字字符比例在 GitHub 中属于正常代码结构，故对代码域取适中型、对其余领域取逆向。已在 $[0, 1]$ 内且方向明确的模型概率不再做秩变换，以保留概率间距。

4.2.2 五语义块与稳定 CRITIC 赋权

按含义把 22 项指标划分为**教育价值**、**表达整洁**、**推理信息**、**噪声重复**、**结构充分**五个语义块（图 4.2）。块内指标信息高度重叠，例如图书、百科、数学三类相似度的相关系数

接近 1；若直接等权，同类信息会被重复计入。因此块内采用 CRITIC 客观赋权 [10]：设指标 j 的标准差为 σ_j ，与同块指标 h 的 Spearman 相关为 r_{jh} ，其信息量为

$$C_j = \sigma_j \sum_{h \in \mathcal{J}_b} (1 - |r_{jh}|). \quad (4.4)$$

为抑制权重对抽样的敏感性，在每域至多 10000 条的分层样本上做 500 次 bootstrap，计算指标跨领域位置统计量的变异系数 CV_j ，得到稳定性修正权重

$$\omega_j = \frac{C_j / (1 + CV_j)}{\sum_{h \in \mathcal{J}_b} C_h / (1 + CV_h)}, \quad \sum_{j \in \mathcal{J}_b} \omega_j = 1. \quad (4.5)$$

块间取等权 1/5，使任何语义维度都不会因包含的指标多而获得更大话语权。样本 i 在块 b 上的评分为有效指标的加权平均

$$B_{ib} = \frac{\sum_{j \in \mathcal{J}_b \cap \mathcal{O}_i} \omega_j u_{ij}}{\sum_{j \in \mathcal{J}_b \cap \mathcal{O}_i} \omega_j}, \quad (4.6)$$

$\mathcal{O}_i$ 为样本 i 的有效指标集合；全部样本均无整块缺失。




图 4.2 22 项同向化指标的相关结构 (a) 与稳定 CRITIC 综合权重 (b)

由图 4.2 可见，指标形成若干明显的相关簇，稳定 CRITIC 自动压低了簇内冗余指标的权重。单项权重最大的平均词长也仅为 0.090，终止标点比例、专业性、教育价值分别为 0.080、0.062、0.061，没有任何单一指标主导综合评分。

4.3 质量冲突的识别与消解

4.3.1 冲突的定义

定义 4.1 (显著质量冲突) 记样本 i 的块间极差 $K_i = \max_b B_{ib} - \min_b B_{ib}$ 。若同时满足

$$K_i > Q_{0.90}(K | d(i)), \quad \max_b B_{ib} \geq 0.75, \quad \min_b B_{ib} \leq 0.25, \quad (4.7)$$

则称样本 i 存在显著质量冲突，其中 $Q_{0.90}(K | d)$ 为所属领域 d 内 K 的 90% 分位。冲突类型记为“最高块 > 最低块”。

条件一保证冲突是**领域内相对**罕见的，避免把代码、论文等领域天然的指标差异误判为冲突；条件二、三保证冲突是**绝对**显著的，即确有一个维度“很好”而另一个维度“很差”。

4.3.2 消解规则：Huber 稳健聚合

对非冲突样本，块间等权平均即可；对冲突样本，简单平均会被极端块拉偏，因此采用 Huber 位置估计 [11]：


$$Q_i = \begin{cases} \frac{1}{|\mathcal{B}_i|} \sum_{b \in \mathcal{B}_i} B_{ib}, & i \notin \mathcal{C}, \\ \arg \min_{q \in [0,1]} \sum_{b \in \mathcal{B}_i} \rho_{1.345} \left(\frac{B_{ib} - q}{s_{d(i),b}} \right), & i \in \mathcal{C}, \end{cases} \quad (4.8)$$

其中 $\mathcal{C}$ 为冲突样本集， $s_{d,b}$ 为领域 d 中块 b 的 MAD 稳健尺度， ρ_c 为 Huber 损失 ($|t| \leq c$ 时取 $t^2/2$ ，否则取 $c|t| - c^2/2$)。Huber 估计对“多数块一致、个别块离群”的情形自动降低离群块的权重，但**不删除任何信息**：冲突强度 K_i 与冲突类型作为附加标签保留。所有冲突样本的 IRLS 迭代均收敛。

4.3.3 冲突结构与成因

在 261086 条记录中，显著冲突率为 3.17% (8270 条)。图 4.3 给出冲突的领域分布与块对结构，主要发现如下。

- (1) **冲突几乎全部指向“结构充分”块**。在全部冲突中，低分块为结构充分的占 93.4%，其中“推理信息高一结构充分低”3640 条、“噪声重复（即干净）高一结构充分低”2290 条、“表达整洁高一结构充分低”1353 条。
- (2) **成因是“形式指标”与“内容指标”测量对象不同**。结构块由文本长度、句数、平均词长构成，刻画的是篇幅形式；推理、教育、表达等块刻画的是内容。arXiv 片段中大量公式与符号使平均词长和句子切分偏离自然语言中心，形成“推理高一结构低”（占该域冲突的 87.7%）；C4 网页多为短小但行文规范的段落，形成“表达高一结



8270 条冲突样本 Huber 校正量：均值 0.077，中位数 0.038

图 4.3 质量冲突的领域分布与类型构成 (a)，以及“高分块 → 低分块”冲突计数 (b)

构低” (91.2%)；代码文本重复少、噪声低，但行与“句”的结构不符合自然语言规律，形成“噪声低—结构低” (42.1%)。

(3) **消解是局部的**。Huber 修正对 252816 个非冲突样本为零；对 8270 个冲突样本，修正量均值 0.077、中位数 0.038。即稳健聚合只调整内部矛盾的样本，不改变整体评分基线。

扩展集检验。arXiv 与 GitHub 两域的记录绝大部分来自扩展集 A2、A3（分别占 91.9% 与 95.1%）。在这两个以扩展集为主体的领域中，上述结论同样成立：冲突的低分块全部或绝大部分为结构充分块（arXiv 为 100%，GitHub 为 93.0%）；冲突率分别为 10.00% 和 2.45%，与“公式密集文本冲突多、代码文本冲突少”的成因解释相符。

4.4 领域质量评价与抽样集对照

4.4.1 领域聚合

样本质量 Q_i 的取值范围为 $[0.141, 0.880]$ 。对领域 d ，取领域内 Q_i 的 Huber 稳健均值作为领域质量

$$q_d = \arg \min_q \sum_{i \in S_d} \rho_{1.345} \left(\frac{Q_i - q}{s_d} \right), \quad (4.9)$$

它介于均值与中位数之间，既不被少量极端样本左右，又比中位数更有效率；并以领域内 500 次 bootstrap 的 2.5%、97.5% 分位作为区间。结果见表 4.2 与图 4.4(a)。

C4 与 CommonCrawl 质量最高——二者本身就是经过规则过滤的网页语料 [12]；GitHub 最低，这是因为多数质量指标（教育价值、流畅度、可读性）面向自然语言设计，代码天然处于劣势。该排序反映的是本指标体系下的相对质量，并非对代码数据训练价值的否定。

表 4.2 七个质量域的领域质量 q_d 与冲突率（全量去重数据）

领域	样本数	q_d	95% 区间	中位数	冲突率/%
C4 网页	10000	0.6192	[0.6173, 0.6210]	0.6201	6.83
通用网页 (CommonCrawl)	9640	0.6083	[0.6067, 0.6097]	0.6106	1.88
学术论文 (arXiv)	17523	0.5688	[0.5679, 0.5697]	0.5663	10.00
技术问答 (StackExchange)	10000	0.5608	[0.5591, 0.5624]	0.5612	3.14
图书 (Book)	171	0.5100	[0.4995, 0.5215]	0.5134	9.36
百科 (Wikipedia)	10000	0.5067	[0.5047, 0.5084]	0.5038	3.22
代码 (GitHub)	203752	0.4304	[0.4301, 0.4306]	0.4296	2.45




图 4.4 七个质量域的质量分布 (a) 与 17 个配比域的映射质量 (b)

4.4.2 全量结果与抽样集 A1 的对照

题目要求将基于全量记录的域级 Q 与抽样集结果对照。扩展集只覆盖 arXiv 与 GitHub 两域，因此在这两域上比较 A1 抽样记录与扩展集余集（去重后不在 A1 中的记录）的质量分布，见表 4.3 与图 4.5。

两域的主体分位数几乎重合：中位数差分别仅为 0.0001 和 0.0015，KS 距离为 0.025 和 0.011，Wasserstein 距离为 0.0029 和 0.0011，Huber 均值差的 bootstrap 区间均包含 0。因此基于抽样集与基于全量数据得到的域级质量结论一致。唯一值得注意的差异出现在 arXiv

表 4.3 A1 抽样集与扩展集余集的质量分位数对照

领域	数据	样本数	P_{10}	P_{25}	P_{50}	P_{75}	P_{90}	KS 距离
arXiv	A1 抽样集	1419	0.5090	0.5356	0.5664	0.6057	0.6752	0.025
	扩展集余集	16104	0.5076	0.5340	0.5663	0.6024	0.7519	
GitHub	A1 抽样集	10000	0.3571	0.3927	0.4310	0.4696	0.5103	0.011
	扩展集余集	193752	0.3566	0.3916	0.4295	0.4691	0.5101	

的高分尾部：arXiv 质量分布在 0.78 附近有一个次高峰，扩展集余集更早进入该峰，使 P_{90} 处的位移达到 0.077 (bootstrap 区间 $[-0.052, 0.122]$ ，仍包含 0)。样本量仅 1419 的 A1 对高分尾部的刻画精度有限，这也是本文坚持用全量记录计算域级 Q 的原因。




图 4.5 A1 抽样集与扩展集余集的分布对照 (a) 及分位数位移函数 (b)

4.4.3 评分可靠性检验

从三个角度检验评分的可靠性。

(1) **聚合规则扰动**。不重新调参，分别改用指标等权、块内等权、取消 Huber、块中位数四种方案。七域排序与主方案的 Kendall 系数最低为 0.810，说明领域层面的质量排序稳健；但样本高、低质量极端组的最低重合率为 0.613，说明单个文本的精细排名对融合规则更敏感。因此本文把领域级 q_d 作为后续建模的主要输入，而不直接使用样本级排名。

(2) **原始文本检验**。回到 A1 原始文本，按领域取 Q_i 的最高 10% 与最低 10% 两组，比较不依赖任何质量指标的五项文本特征：控制/替换字符率、HTML 与脚本密度、纯 URL 行比例、重复行比例、超长 Token 比例。若评分可靠，高质量组的这五项“脏数

据”特征应系统性地低于低质量组。【待补：运行问题一/`problem1.py all`后，将 `results_p12_final_v2/text_proxy_validation.csv` 中各领域 `high_minus_low` 的结果填入此处（建议列成一张 7 域 × 5 特征的小表），并据符号给出结论】

(3) 与外部认知一致。C4、CommonCrawl 质量最高、代码最低，与 FineWeb 等工作中“经规则过滤的网页语料教育价值较高”的结论一致 [12, 13]；arXiv 冲突率最高，也与公式文本难以被自然语言指标刻画的常识一致。

4.4.4 质量向 17 个配比域的映射

质量数据有 7 个领域，配比实验有 17 个 The Pile 领域 [14]。参照 A16，3 个领域直接映射（arXiv、GitHub、StackExchange），3 个近直接映射（Pile-CC→CommonCrawl、Wikipedia(en)→Wikipedia、Gutenberg→Book）。其余 11 个领域用 A18 原始文本的长度、字符、结构与重复特征计算其到 7 个锚点的标准化距离 d_{md} ，按温度 τ 的软最近邻加权并向公共均值 $\bar{q}$ 收缩：

$$w_{md} = \frac{\exp[-(d_{md} - d_{m,\min})/\tau]}{\sum_{h=1}^7 \exp[-(d_{mh} - d_{m,\min})/\tau]}, \quad q_m = \lambda_m \sum_{d=1}^7 w_{md} q_d + (1 - \lambda_m) \bar{q}. \quad (4.10)$$

τ 只由已知域的留一误差选择（ $\tau = 5$ ，留一 MAE = 0.057）。但留一排序的 Spearman 系数为 -1 ，说明文本表层特征不能可靠地区分推断域的质量高低；按照预设规则，11 个推断域的收缩系数 λ_m 取 0，统一取公共参考质量 $\bar{q} = 0.5435$ （bootstrap 区间 $[0.5419, 0.5451]$ ），如图 4.4(b) 所示。这一处理不会低估质量的作用：配比对 Loss 的影响在配比模型中由实验数据直接估计，质量映射只用于构造基线质量 Q_0 。

4.5 领域配比—Loss 响应模型

4.5.1 Scheffé 混料模型

17 个份额满足式 (4.1) 的单纯形约束，属于组成数据 [15]。含截距的普通多项式回归会因 $\sum_i p_i = 1$ 产生完全共线。Scheffé 正则多项式 [7, 8] 去掉截距与平方项，把约束直接吸收进模型结构。对第 k 个验证域，

$$\hat{L}_k(\mathbf{p}) = \sum_{i=1}^{17} \beta_{ik} p_i + \sum_{1 \leq i < j \leq 17} \beta_{ijk} p_i p_j, \quad k = 1, \dots, 13. \quad (4.11)$$

一次项 β_{ik} 是“纯领域 i 训练”时的预测 Loss；交互项 $\beta_{ijk} < 0$ 表示领域 i, j 同时出现时 Loss 低于线性混合，即二者互补， $\beta_{ijk} > 0$ 则表示替代（或冗余）。模型共 $17 + 136 = 153$ 个特征，而训练配方只有 512 组，因此对 13 个验证域联合做多输出 Ridge 估计 [16]：

$$\hat{\mathbf{B}} = \arg \min_{\mathbf{B}} \|\mathbf{Y} - \mathbf{X}_s \mathbf{B}\|_F^2 + \lambda \|\mathbf{B}\|_F^2, \quad (4.12)$$

其中 $\mathbf{X}_s$ 为按训练折均方根尺度标准化的 Scheffé 设计矩阵， $\mathbf{Y} \in \mathbb{R}^{512 \times 13}$ 。

质量是否需要单独进入该模型？若加入配比加权质量 $\sum_i p_i q_i$ ，它是一次项的线性组合，与 Scheffé 一次项完全共线，无法从配比实验中识别。因此**领域质量的作用已被一次项吸收**，不单独入模；质量对 Loss 的独立作用在问题二中由附件 B 的质量实验识别。

4.5.2 模型选择

在 A4/A5 内按配比结构分层做五折交叉验证，标准化只在训练折内估计，以 13 个验证域的 IQR 标准化 RMSE（NRMSE）为主准则。候选模型比较见图 4.6：二阶 Ridge 的 NRMSE 最低 (0.3959)，优于 Elastic Net (0.3986)、线性 Ridge (0.4108)、Extra Trees (0.4307) 与随机森林 (0.4423)。Extra Trees 的秩相关略高 (中位 Spearman 0.8545 对 0.8285)，二者共同构成“误差—排序” Pareto 前沿；二阶 Ridge 在误差上占优，并且是连续可微的显式多项式，可以直接用于梯度分析和约束寻优，故选为主模型。正则化路径显示最优 $\alpha^* = 0.0562$ 附近存在 NRMSE 与最优值相差不超过 1% 的宽平台 [0.0018, 0.178]，选择并非由单个网格点偶然决定。




图 4.6 配比响应模型的交叉验证选择 (a) 与 Ridge 正则化路径 (b)

4.6 配比模型的求解结果

4.6.1 检验集验证与外推稳健性

模型选定后冻结，一次性作用于 A6–A15，结果见表 4.4 与图 4.7。

三点结论：**第一**，在三个实测检验集上 Spearman 系数稳定在 0.85–0.87，说明 1M 规模上学到的配比响应能够跨越三个数量级（1M→1B）保持配方的**相对优劣**；归一化后悔值随规模增大而下降（0.188 → 0.061），即按模型选出的配方与真实最优配方的差距越来越小。**第二**，1B 上 R^2 降至 0.324，说明绝对 Loss 的校准随规模减弱——这正是问题二中把配比效应写成“相对可约损失”的实证依据：配比改变的是 Loss 的相对排序与比例，而非

表 4.4 配比响应模型在检验集与外推表上的表现（13 个验证域的中位数）

数据	性质	Spearman	Kendall	R^2	归一化后悔值
A6/A7 (1M)	实测，同规模新配方	0.858	0.666	0.637	0.188
A8/A9 (60M)	实测，跨规模	0.870	0.683	0.675	0.140
A10/A11 (1B)	实测，跨规模新配方	0.850	0.688	0.324	0.061
A12/A13 (10B)	估算标签	0.540	0.381	-231.4	0.743
A14/A15 (70B)	估算标签	0.394	0.258	-373.5	0.806




图 4.7 1M、60M、1B 三个实测检验集上的预测 Loss 与真实 Loss

固定的绝对差值。**第三**，在 10B、70B 估算表上排序能力明显下降（Spearman 0.54、0.39）， R^2 大幅为负。由于这两张表是估算标签，不能据此否定模型，但它提示：**配比结论的排序外推以 1B 为可靠上限**，更大规模须结合问题二的尺度不变性检验谨慎使用。

4.6.2 领域效应：边际收益与起点依赖

在单纯形上单独增加某一份额必然压缩其他份额。为给出可解释的方向效应，在参考配比 p_{ref} （512 组训练配方的平均）处，把梯度相对 17 域平均梯度中心化，并对 13 个验证域取平均：

$$E_i = -\frac{1}{13} \sum_{k=1}^{13} \left[\frac{\partial \hat{L}_k}{\partial p_i} - \frac{1}{17} \sum_{j=1}^{17} \frac{\partial \hat{L}_k}{\partial p_j} \right]_{p=p_{\text{ref}}} \quad (4.13)$$

$E_i > 0$ 表示在总份额不变时，向领域 i 转移份额会降低 Loss。结果见图 4.8(a)：技术对话（Ubuntu IRC， $E = 3.66$ ，95% 区间 $[2.47, 4.91]$ ）与数学推理（DM Mathematics， $E = 1.57$ ， $[0.57, 2.64]$ ）是仅有的两个区间完全为正的领域；生医摘要、网页语料、法律、代码、学术论文、专利、生物医学全文、英文百科、技术问答九个领域的区间完全为负。换言之，在参考配比附近，**稀缺的对话与数学数据最值得增配**，而占比大的通用长文本领域已处于**边际收益为负**的区间。




图 4.8 参考配比处的领域方向边际收益 (a) 与两两领域交互 (b)

式 (4.13) 只描述 p_{ref} 附近的一阶方向。为考察其是否依赖起点，在全部 512 个训练配方上做“局部替换”：按比例压缩其余 16 域、向目标领域转入 2% 份额，计算 13 域平均 Loss 的降低量 (图 4.9)。技术对话、商务邮件与数学推理的中位降低量分别为 0.107、0.097 和 0.066，技术对话与数学推理在 91% 的起点上有利；而哲学论文的有利占比只有 52%，其效应不稳定。更重要的是，**17 个领域中有 14 个的增配收益与原有份额负相关** (Spearman 系数 -0.26 至 -0.69 ，技术对话为 -0.66)，呈现清晰的边际收益递减——这与数据混合律 [17, 18] 中“小领域少量增配收益最大”的经验一致。

4.6.3 领域组合：互补为主，未见稳定替代

对 136 个交互系数做 500 次训练行 bootstrap (图 4.8(b))。其中 75 对的 95% 区间完全小于 0，是**稳定互补**关系；有 15 对点估计为正 (替代方向)，但**没有一对**的区间完全大于 0。互补最强的组合集中在“稀缺小领域 $\times$ 其他领域”，例如科研项目—技术对话、技术对话—科技论坛、数学推理—技术对话、生物医学全文—科技论坛。这表明：在当前实验范围内，不同领域的数据主要是**互补品**而非替代品，混合多样化领域比集中投入单一领域更有效。

领域质量 q_m 与边际收益 E_i 的 Spearman、Kendall 系数分别为 -0.143 、 -0.105 ，二者没有正向单调关系：**质量高的领域不一定是该增配的领域**。静态质量与动态配比收益是两个不同维度，这为问题二把质量与配比作为两条独立通道写入标度律提供了依据。




图 4.9 512 个训练配方上转入 2% 份额的局部 Loss 降低量

4.6.4 支持域约束下的近优配比

13 个验证域的 Loss 尺度不同，直接平均会让高波动领域主导目标。取训练集中第 k 个验证域 Loss 的四分位距 s_k 作尺度，定义综合目标

$$J(\mathbf{p}) = \frac{1}{13} \sum_{k=1}^{13} \frac{\hat{L}_k(\mathbf{p})}{s_k}. \quad (4.14)$$

二阶响应面只在训练配方附近可靠，远离实验范围的“最优解”没有意义。令 u_i 为训练配方中第 i 个份额的 99% 分位， σ_p 为份额标准差，候选配比到训练集的标准化最近距离为 $d(\mathbf{p}) = \min_r \|(\mathbf{p} - \mathbf{p}_r)/\sigma_p\|_2$ ，支持半径 R_s 取训练点最近邻距离的 99% 分位。于是配比优化模型为

$$\min_{\mathbf{p}} J(\mathbf{p}) \quad \text{s.t.} \quad p_i \geq 0, \quad \sum_{i=1}^{17} p_i = 1, \quad p_i \leq u_i, \quad d(\mathbf{p}) \leq R_s. \quad (4.15)$$

以 30 个训练配方及其凸组合为起点做 SLSQP 求解，并用 10000 个随机可行点做反证检查；在 200 次训练行 bootstrap 中重新拟合并重新优化，得到各份额的不确定区间。

结果见表 4.5 与图 4.10。近优配比的目标值为 $J(\mathbf{p}^*) = 4.765$ ，优于 10000 个随机可行点中的最好值 5.207；约束回代的份额和误差为 0、上界违反量 1.3×10^{-14} ，支持距离恰好等于支持半径 (4.330)，即支持域约束起作用。优化的结构性规律非常清楚：

- (1) **压缩边际收益为负的大领域**：生物医学全文、学术论文、代码、法律四域由合计 43.4% 压缩至 0，网页语料由 12.0% 压缩至 3.6%，这五个领域均属图 4.8(a) 中区间显著为负的九个领域；

表 4.5 近优配比 p^* 与参考配比 p_{ref} 的对比 (单位: %)

领域	p_{ref}	p^*	bootstrap 95% 区间	调整方向
专利背景 (USPTO)	7.56	24.19	[0.00, 55.61]	承接份额
生医摘要 (PubMed Abs.)	6.62	18.91	[0.00, 53.09]	承接份额
技术问答 (StackExchange)	9.94	14.91	[0.00, 51.08]	增配
议会文本 (Europarl)	1.27	10.38	[0.00, 10.38]	增配至上界
科技论坛 (HackerNews)	1.17	7.15	[0.00, 11.11]	增配
哲学论文 (PhilPapers)	0.55	4.88	[0.00, 4.88]	增配至上界
技术对话 (Ubuntu IRC)	1.96	3.40	[0.00, 16.98]	增配
商务邮件 (Enron)	0.22	2.09	[0.00, 2.40]	增配至近上界
生物医学全文、学术论文、代码、法律	43.43	0.00	—	压缩至 0
网页语料 (Pile-CC)	11.95	3.55	[0.00, 27.52]	大幅压缩

- (2) **把稀缺的小领域推到经验上界**: 议会文本、哲学论文触及上界, 商务邮件接近上界, 科技论坛增至上界的约 $2/3$ ——受限于实验中这些领域从未被大量使用, 模型不敢把份额推得更远;
- (3) **由专利背景与生医摘要承接剩余份额**: 它们在参考配比处的一阶边际收益虽为负, 却与多个小领域存在稳定互补 (如专利背景—科技论坛), 说明份额调整由交互项而非一阶边际主导, 二者是“承载”小领域收益的载体领域。

需要说明的是, 各份额的 bootstrap 区间较宽、多数领域有落到零的可能, 且最优的 5 个起点目标值相对离散度为 1.6%。因此 p^* 应理解为“当前实验支持的**近优配比族**的代表”, 其结构性方向 (压缩大领域、增配稀缺领域) 比单个份额的精确数值更可靠。

4.6.5 近优配比的参数敏感性

分别把支持半径分位、份额上界分位由 99% 收紧到 97.5%、95%, 把 Ridge 正则强度改为 $0.5\alpha^*$ 、 $2\alpha^*$, 每个情景都重新做 30 起点优化 (图 4.11)。正则强度扰动下, 配比的 L_1 变化仅 2.8、3.9 个百分点, 目标值几乎不变 ($< 0.02\%$); 而收紧支持半径至 95% 使配比变化 20.1 个百分点、目标上升 2.6%, 收紧份额上界至 95% 使配比变化 61.4 个百分点、目标上升 3.4%。结论是: **近优对比对模型估计稳健, 对“允许偏离实验范围多远”敏感**, 扩大配比实验的覆盖范围是进一步提升配比收益的关键。

4.7 问题一小结




图 4.10 近优配比相对参考配比的调整及其不确定性




图 4.11 近优配比对支持域、份额上界与正则强度的敏感性

问题一主要结论

- (1) 构建“同向化—五语义块—稳定 CRITIC—Huber 冲突消解”质量评价模型，得到 26.1 万条独立记录的样本级与领域级质量：C4 (0.619) > CommonCrawl (0.608) > arXiv (0.569) > StackExchange (0.561) > Book (0.510) > Wikipedia (0.507) > GitHub (0.430)；聚合规则扰动下七域排序 Kendall 系数最低为 0.81。
- (2) 显著冲突率为 3.17%，其中 93.4% 的冲突以“结构充分”块为短板，成因是形式指

标与内容指标的测量对象不同；这一结论在以扩展集为主体的 arXiv、GitHub 两域同样成立。抽样集与全量数据的域级质量一致 (KS 距离 ≤ 0.025)，仅 arXiv 高分尾部存在差异。

- (3) 二阶 Scheffé–Ridge 混料模型在 1M、60M、1B 实测检验集上的 Spearman 系数为 0.858、0.870、0.850；技术对话与数学推理增配收益显著为正，领域间以互补为主 (75 对稳定互补、0 对稳定替代)。近优配比压缩生物学全文、学术论文、代码、法律等大领域，增配稀缺的对话、论坛、议会与哲学文本。
- (4) 向问题二输出：基线质量 $Q_0 = \mathbf{p}_{\text{ref}}^T \mathbf{q} = 0.5390$ ，参考配比 $\mathbf{p}_{\text{ref}}$ ，近优配比 $\mathbf{p}^*$ ，以及标准化配比响应 $R(\mathbf{p})$ (见式 (5.11))。

5 问题二：跨维度数据融合与广义标度律

5.1 建模思路与可检验假设

附件中没有同时改变 N, D, Q, p 的联合实验：B1 只改变 (N, D) ；B7 在固定的 (N, D) 网络上改变质量；附件 A 只改变配比。因此广义标度律必须具有**可分结构**——每一项只由一类数据识别——再用可检验的假设把它们统一起来。我们提出如下三条假设，并在后文逐一检验：

假设 5.1 (参数—数据可分) 在固定质量与配比下， $Loss$ 为不可约项、参数项、数据项之和，即 $L = E + An^{-\alpha} + Bd^{-\beta}$ ，参数与数据之间无额外交互。（检验：§5.2，与含交互项模型对比。）

假设 5.2 (质量加性惩罚且可退化) 数据质量偏离理想状态时，在经典项之上产生附加损失 $\Delta_Q(Q) \geq 0$ ，且 $\Delta_Q(1) = 0$ ，即 $Q = 1$ 时广义标度律严格退化为经典形式。（检验：§5.3，四种质量函数形式的成块交叉验证。）

假设 5.3 (配比效应尺度不变) 领域配比按比例缩放**可约损失** $L - E$ ，缩放因子 $\exp[\theta R(p)]$ 中的系数 θ 不随模型规模变化。这是连接附件 A（配比实验）与附件 B（规模实验）的桥梁：两套实验的绝对 $Loss$ 不可比，但“可约损失被配比改变了百分之几”是无量纲、可迁移的。（检验：§5.4，附件 A 的 *1M*、*60M*、*1B* 三个规模。）

数据的使用分工见表 5.1。B6–B8、B10 为半合成或估算数据，本文只将其用于补充分析与边界检验，不作为直接实验观测。

5.2 经典标度律

5.2.1 候选模型与估计方法

记 $n = N/10^9$ ， $d = D/10^9$ 。比较三种候选结构：

$$M_0: L = E + An^{-\alpha} + Bd^{-\beta}, \quad (5.1)$$

$$M_C: L = E_C + K_C(6nd)^{-\zeta}, \quad (5.2)$$

$$M_{ND}: L = E + An^{-\alpha} + Bd^{-\beta} + G(nd)^{-\xi}. \quad (5.3)$$

M_0 即 Chinchilla 形式 [2]； M_C 假设 $Loss$ 只依赖总算力 [1]； M_{ND} 在 M_0 上加入参数—数据交互项，用于检验假设 5.1。所有系数与指数约束为正（对数参数化 $\theta = e^\eta$ ），保证 $Loss$ 随资源单调不减。以模型规模为聚类单元赋等权，用 Huber 稳健非线性最小二乘估计，并以拉丁超立方采样的 50 个起点避免局部极小。模型评价采用**留一参数规模**交叉验证：每次留出一个规模的整条轨迹，这比随机留点更严格地检验了对新规模的外推能力。

表 5.1 问题二的数据分工

数据	性质	用途
B1	真实训练轨迹, 8 个参数规模、1176 个检查点	经典标度律主拟合与留一规模验证
B2	半合成族外轨迹	冻结参数后的族外验证
B4 / B5	跨模型族记录 / 文献数据	跨族与文献验证
B6 / B7	质量分块实验 (B6 为 B7 子集), 45 个 (N, D) 单元 $\times$ 10 档质量	B7 拟合质量项, B6 做一致性核对
B8	扩展质量网格 (半合成)	压力测试与外推边界
B9 / B10	百亿参数以上模型信息 / 估算 Loss	大规模外推讨论
A4-A11	问题一的配比实验与检验集	配比效应系数 θ 的标定与尺度不变性检验

5.2.2 结果

表 5.2 经典标度律候选模型的留一参数规模验证

模型	留一规模 RMSE	归一化 RMSE	参数个数
M_0 (可分幂律)	1.47×10^{-4}	3.74×10^{-4}	5
M_C (总算力幂律)	8.49×10^{-2}	2.16×10^{-1}	3
M_{ND} (含交互项)	1.48×10^{-4}	3.76×10^{-4}	7

由表 5.2: (1) M_C 的误差比 M_0 大近 600 倍, 说明相同算力下 N 与 D 的分配方式对 Loss 有决定性影响, 这正是问题三资源配置有意义的前提; (2) M_{ND} 增加两个参数后误差没有下降, 交互项不提供额外解释力, **假设 5.1 成立**。按一倍标准误原则选择 M_0 , 500 次聚类 bootstrap 给出的参数及 95% 区间为

$$\begin{aligned}
 E &= 1.6898 [1.6897, 1.6899], \quad A = 0.3540 [0.3539, 0.3541], \quad \alpha = 0.3400 [0.3399, 0.3401], \\
 B &= 1.2403 [1.2402, 1.2404], \quad \beta = 0.2799 [0.2798, 0.2799].
 \end{aligned} \tag{5.4}$$

图 5.1(b) 给出一个更直观的检验: 若 M_0 正确, 则扣除参数项后的“剩余损失” $L - E - An^{-\alpha}$ 应只依赖 d 。8 个规模、共 1176 个检查点在双对数坐标下**坍塌到同一条斜率为 $-\beta$ 的直线上**, 各规模残差 RMSE 均在 $(1.0 \sim 2.1) \times 10^{-4}$ 之间且中位数接近 0。剔除 $D < 2B$ 的 32 个早期检查点后重新拟合, 参数的最大相对变化仅 0.053%。

由 M_0 可以直接推出计算最优配置的标度指数: 在 $C = 6ND$ 约束下最小化 L 得




图 5.1 经典标度律：B1 八个规模的拟合 (a)、数据坍缩检验 (b) 与各规模残差 (c)

$N^* \propto C^{\beta/(\alpha+\beta)} = C^{0.452}$, $D^* \propto C^{\alpha/(\alpha+\beta)} = C^{0.548}$, 与 Chinchilla 研究报告的 0.46/0.54 高度一致 [2, 19]。这为本文标度律的外部有效性提供了文献层面的佐证。

5.3 质量修正项

5.3.1 候选形式

在固定 B1 经典参数的前提下，用 B7 质量网格估计质量惩罚项 Δ_Q 。设计四种满足 $\Delta_Q(1) = 0$ 的候选形式，分别对应四种关于“质量如何起作用”的机制假说：

$$\text{GQ1 (有效样本量)} : \Delta_Q = Bd^{-\beta} (Q^{-\gamma} - 1), \quad (5.5)$$

$$\text{GQ2 (加性惩罚)} : \Delta_Q = c_Q(1 - Q)^{\nu_Q}, \quad (5.6)$$

$$\text{GQ3 (指数变化)} : \Delta_Q = Bd^{-\beta} [e^{b_Q(1-Q)} d^{-\beta_1(1-Q)} - 1], \quad (5.7)$$

$$\text{GQ4 (双通道)} : \Delta_Q = An^{-\alpha} (Q^{-\alpha\gamma_N} - 1) + Bd^{-\beta} (Q^{-\beta\gamma_D} - 1). \quad (5.8)$$

GQ1 把低质量数据视为“打了折扣的有效 Token” ($D_{\text{eff}} = Q^{\gamma/\beta} D$)，与数据受限标度律的思想一致 [4]；GQ2 认为低质量引入一个与规模无关的额外损失；GQ3 允许质量改变数据项的指数；GQ4 让质量同时折扣参数与数据的有效规模。

5.3.2 成块交叉验证选择

为避免信息泄漏，验证按**参数规模、数据规模、质量水平、 (N, D) 单元**四种方式成块留出（共 69 个留出块），四类切分等权，且验证折中不提供该单元 $Q = 1$ 的基线 Loss。结果见图 5.2。

GQ2 在全部四种切分下误差均最低（nRMSE 0.143–0.155，GQ1 为 0.225–0.264），等权 RMSE 为 0.0720，比 GQ1 低 38.7%；在 69 个留出块中 GQ2 最优的有 41 个。GQ3 与 GQ2




图 5.2 质量修正项的成块交叉验证：各切分误差 (a)、等权 RMSE (b) 与 GQ2 留单元预测 (c)

参数个数相同，其等权 RMSE (0.0744) 落在一倍标准误差阈值 (0.0747) 之内、差异不显著；GQ2 误差最低且形式最简、可解释性最好，故选择 GQ2。留 (N, D) 单元验证中，GQ2 预测与观测的 Spearman 系数达 0.982，只在高 Loss 尾部略有低估。500 次单元聚类 bootstrap 给出

$$c_Q = 0.3620 [0.3327, 0.3923], \quad \nu_Q = 0.990 [0.918, 1.068]. \quad (5.9)$$

ν_Q 的区间包含 1，说明在 B7 支持域内质量惩罚近似与质量缺口 $1 - Q$ 成正比：质量每提高 0.1，Loss 约降低 0.036 (bootstrap 95% 区间 $[0.033, 0.039]$)，且这一收益不随模型规模衰减——这正是后文“规模越大、质量越值钱”的根源。

GQ2 优于 GQ1 的事实本身也有含义：若低质量只是“稀释了有效 Token”，其损害应随 D 增大而减小 (GQ1)；数据却支持一个与 D 无关的惩罚。这表明低质量数据带来的损失无法靠堆砌数据量弥补，与数据剪枝研究中“质量可突破幂律”的发现相呼应 [20]。

5.3.3 与问题一质量尺度的对接

问题一的质量评分 Q_A 与 B7 的质量字段来自不同体系。以问题一参考配比对应的质量 $Q_{\text{ref}} = \mathbf{p}_{\text{ref}}^T \mathbf{q} = 0.5390$ 为公共锚点，令

$$Q_{\text{eff}} = \text{clip}[Q_{\text{ref}} + s_Q(Q_A - Q_{\text{ref}}), \varepsilon, 1], \quad s_Q \in \{0.5, 1, 1.5\}, \quad (5.10)$$

主情景取 $s_Q = 1$ (两套质量尺度等距对应)， $s_Q = 0.5, 1.5$ 用于敏感性分析。这样，问题一的领域质量与配比通过基线质量 $Q_0(\mathbf{p}) = \mathbf{p}^T \mathbf{q}$ 进入广义标度律。

5.4 配比修正项与尺度不变性检验

5.4.1 标准化配比响应

由问题一的 Scheffé–Ridge 响应面 $\hat{L}_k(\mathbf{p})$ 与综合目标 $J(\mathbf{p})$ (式 (4.14)), 定义以参考配比为零点的标准化配比响应

$$R(\mathbf{p}) = \frac{J(\mathbf{p}) - J(\mathbf{p}_{\text{ref}})}{\text{IQR}_{A4}[J]}, \quad R(\mathbf{p}_{\text{ref}}) = 0, \quad (5.11)$$

分母为 512 组训练配方上 J 的四分位距。 $R < 0$ 表示配比优于参考配比；问题一的近优配比 $R(\mathbf{p}^*) = -2.290$ (bootstrap 95% 区间 $[-3.568, 0.113]$)。

5.4.2 系数 θ 的标定

在附件 A 的三个实测检验规模 (1M、60M、1B) 上, 分别以 $R(\mathbf{p})$ 为自变量、13 域平均 Loss 为因变量做稳健回归, 得到截距 $\bar{L}(n)$ (参考配比处的平均 Loss) 与斜率 $s(n) = \partial L / \partial R$ 。若假设 5.3 成立, 由 $L = E + (\bar{L} - E)e^{\theta R}$ 得 $\partial L / \partial R|_{R=0} = \theta(\bar{L} - E)$, 于是

$$\theta(n) = \frac{s(n)}{\bar{L}(n) - E}. \quad (5.12)$$

各规模的估计见表 5.3 与图 5.3。

表 5.3 配比效应的绝对强度 $s(n)$ 与相对强度 $\theta(n)$

规模	配方数	Spearman(R, L)	$s(n)$	$\bar{L}(n)$	$\theta(n)$	θ ($E = 1.5$)	θ ($E = 1.9$)
1M	256	0.813	0.2689	5.567	0.0693	0.0661	0.0733
60M	256	0.820	0.2386	4.152	0.0969	0.0900	0.1059
1B	64	0.734	0.0840	2.646	0.0878	0.0733	0.1125
1B 相对 1M 的比值			0.312	—	1.27	1.11	1.53

结果清楚地支持假设 5.3: 规模从 1M 增至 1B (三个数量级), 配比效应的**绝对**强度下降了 69% ($0.269 \rightarrow 0.084$), 但它占可约损失的**相对**比例 θ 始终稳定在 0.07–0.10, 三个规模的变异系数仅 0.17, 取 $E = 1.5$ 时结论不变; 取 $E = 1.9$ 时 θ 随规模略有上升 (1B 与 1M 之比为 1.53), 但这一变化远小于绝对强度 69% 的降幅, 且方向与“配比效应随规模消失”相反。这说明**配比改变的是“剩余可降低部分”的百分比, 而非固定的 Loss 差值**——这也解释了问题一中 1B 上排序保持良好而绝对 R^2 下降的现象, 并与数据混合律中“Loss 对配比呈指数依赖”的经验形式一致 [17]。取三个规模的平均值

$$\theta = 0.0847 \quad (\text{变异系数} 0.17). \quad (5.13)$$




图 5.3 配比效应的跨规模迁移：各验证域斜率 (a)、绝对强度 $s(n)$ (b) 与相对强度 $\theta(n)$ (c)

5.5 广义标度律

5.5.1 模型形式

综合式 (5.1)、(5.6)、(5.10)、(5.11) 与假设 5.3，本文提出的广义标度律为

$$L(N, D, Q, \mathbf{p}) = E + \left[An^{-\alpha} + Bd^{-\beta} + c_Q (1 - Q_{\text{eff}})^{\nu_Q} \right] \cdot \exp[\theta R(\mathbf{p})] \quad (5.14)$$

其中 Q_{eff} 由式 (5.10) 给出，基线质量 $Q_0(\mathbf{p}) = \mathbf{p}^\top \mathbf{q}$ 由问题一的领域质量与配比决定，质量处理可将其提升至 $Q_A \geq Q_0$ 。代入估计值：

$$L = 1.6898 + \left[0.3540 n^{-0.3400} + 1.2403 d^{-0.2799} + 0.3620 (1 - Q_{\text{eff}})^{0.9903} \right] e^{0.0847 R(\mathbf{p})}. \quad (5.15)$$

5.5.2 模型性质

定理 5.1 (广义标度律的基本性质) 式 (5.14) 满足：

- (1) **退化性**：当 $Q_{\text{eff}} = 1$ 、 $\mathbf{p} = \mathbf{p}_{\text{ref}}$ 时， $L = E + An^{-\alpha} + Bd^{-\beta}$ ，严格退化为经典标度律；
- (2) **单调性**： L 关于 N 、 D 、 Q_{eff} 严格递减，关于 $R(\mathbf{p})$ 严格递增；
- (3) **物理下界**：对任意 $N, D, Q, \mathbf{p}$ ，恒有 $L > E$ ，即任何资源组合都不能突破不可约损失；
- (4) **配比可分性**：对任意固定的 $\mathbf{p}$ ， $\arg \min_{N, D, Q} L$ 与 $\mathbf{p}$ 无关。

证明要点。 (1)(2) 由各项的符号直接可得。(3) 方括号内各项为正， $e^{\theta R} > 0$ 。(4) 记方括号

为 $\Phi(N, D, Q)$ ，则 $L = E + \Phi \cdot e^{\theta R(\mathbf{p})}$ ；对固定 $\mathbf{p}$ ， $e^{\theta R}$ 是正常数，最小化 L 与最小化 Φ 等价。□

性质 (3) 是乘性结构相对于加性配比项 $\lambda R(\mathbf{p})$ 的关键优势：加性结构在 R 很负、规模很大时会预测出低于不可约损失的非物理 Loss，乘性结构则天然避免这一问题。性质 (4) 为问题三提供了理论依据：配比决策可以与规模—质量决策**分离求解**。

以参考点 $N = 1\text{B}$ 、 $D = 150\text{B}$ 、 $Q_A = Q_{\text{ref}}$ 为例， $L = 2.517$ ；若改用近优配比 $\mathbf{p}^*$ ，可约损失乘以 $e^{0.0847 \times (-2.290)} = 0.824$ ，Loss 降至 2.371。这一降幅 (0.146) 相当于把数据质量从 0.539 提升到约 0.940——**合理配比的价值与大幅提质相当，且不消耗额外算力**。由于 $R(\mathbf{p}^*)$ 的区间上端略大于 0，该收益应理解为期望收益。

5.5.3 广义标度律地形

图 5.4(a) 给出参考质量下 Loss 在 (N, D) 平面上的等高线，虚线框为 B1/B7 的观测支持域；图 5.4(b) 表明，提高质量会使等 Loss 曲线整体向左下方移动。例如在 $N = 25.8\text{B}$ 处达到 $L = 2.2$ ，质量为 0.40、0.54、0.80 时分别需要约 1100B、447B 和 127B Token：**质量从 0.54 提升到 0.80，可节省约 71% 的训练数据**，这对缓解“数据墙”具有直接意义 [3]。质量为 0.40 时，图示范围内甚至无法达到 $L = 2.0$ 。




图 5.4 广义标度律的 Loss 地形 (a) 与不同质量下的等 Loss 前沿 (b)

5.6 边际效用、弹性与替代条件

5.6.1 边际效用与弹性

对式 (5.14) (取 $p = p_{\text{ref}}$ 、 $s_Q = 1$ 、未触及截断), 各资源的边际效用为

$$-\frac{\partial L}{\partial N} = \frac{\alpha A n^{-\alpha}}{N}, \quad -\frac{\partial L}{\partial D} = \frac{\beta B d^{-\beta}}{D}, \quad -\frac{\partial L}{\partial Q} = c_Q \nu_Q (1-Q)^{\nu_Q-1}, \quad \frac{\partial L}{\partial R} = \theta (L-E). \quad (5.16)$$

为消除量纲, 定义 Loss 弹性 $\epsilon_x = -\partial \ln L / \partial \ln x$:

$$\epsilon_N = \frac{\alpha A n^{-\alpha}}{L}, \quad \epsilon_D = \frac{\beta B d^{-\beta}}{L}, \quad \epsilon_Q = \frac{c_Q \nu_Q Q (1-Q)^{\nu_Q-1}}{L}. \quad (5.17)$$

在参考点, $\epsilon_N = 0.048$ 、 $\epsilon_D = 0.034$ 、 $\epsilon_Q = 0.077$: **质量提高 1% 对 Loss 的改善, 相当于参数量提高 1.6% 或数据量提高 2.3%**。由式 (5.17), ϵ_N, ϵ_D 随规模扩大按幂律衰减, 而 ϵ_Q 的分子与规模无关——**规模越大, 质量的相对重要性越高**。图 5.5(a) 显示, 在 $D = 150B$ 下质量弹性在 $N \approx 0.24B$ 处超过参数弹性; 在 27 个 N - D - Q 网格状态上, 质量弹性在总弹性中的平均份额为 46.0%, 有 16 个状态由质量主导 ($s_Q = 0.5$ 与 1.5 时分别为 30.8%、55.5%)。




图 5.5 资源弹性随参数规模的变化 (a) 与不同质量映射强度下的弹性构成 (b)

5.6.2 质量与规模的替代条件

题目要求推导“质量提升 ΔQ 等价于参数增加多少”的可计算条件。固定其余变量, 令质量提升带来的 Loss 降幅为

$$\delta_Q(\Delta Q) = c_Q [(1-Q)^{\nu_Q} - (1-Q-\Delta Q)^{\nu_Q}] e^{\theta R(p)}. \quad (5.18)$$

定理 5.2 (质量—规模替代条件) 在广义标度律 (5.14) 下, 存在有限的参数量增幅 r_N , 使

$$L(N(1+r_N), D, Q) = L(N, D, Q + \Delta Q)$$

成立的充要条件是

$$\delta_Q(\Delta Q) < A n^{-\alpha} e^{\theta R(p)}, \quad (5.19)$$

即质量提升带来的收益小于参数项的全部剩余可降低量。此时等价增幅有闭式解

$$r_N = \left[1 - \frac{\delta_Q}{A n^{-\alpha} e^{\theta R}} \right]^{-1/\alpha} - 1, \quad r_D = \left[1 - \frac{\delta_Q}{B d^{-\beta} e^{\theta R}} \right]^{-1/\beta} - 1, \quad (5.20)$$

其中 r_D 的存在条件为 $\delta_Q < B d^{-\beta} e^{\theta R}$ 。

证明。 等价方程为 $A n^{-\alpha} [1 - (1+r_N)^{-\alpha}] e^{\theta R} = \delta_Q$ 。左端关于 $r_N \in (0, \infty)$ 连续严格递增, 取值范围为 $(0, A n^{-\alpha} e^{\theta R})$, 故有解当且仅当式 (5.19) 成立, 解出即得式 (5.20)。 r_D 同理。□

数值结果。 在参考点 ($N = 1\text{B}$ 、 $D = 150\text{B}$ 、 $Q = 0.539$ 、 $\mathbf{p} = \mathbf{p}_{\text{ref}}$) 取 $\Delta Q = 0.1$, 得 $\delta_Q = 0.0362$, 代入式 (5.20):

$$r_N = 37.3\%, \quad r_D = 56.9\%, \quad (5.21)$$

即质量提高 0.1 的 Loss 改善, 等价于参数量增加 37.3% 或训练数据量增加 56.9% (图 5.6(a)), 与数值求根结果完全一致。

替代的临界规模。 条件 (5.19) 的右端随 n 递减。令其等于 δ_Q , 得到临界规模

$$n_c = \left(\frac{A}{\delta_Q} \right)^{1/\alpha}, \quad d_c = \left(\frac{B}{\delta_Q} \right)^{1/\beta}. \quad (5.22)$$

对 $\Delta Q = 0.1$, $N_c \approx 820\text{B}$ 、 $D_c \approx 3.1 \times 10^{14}$ Token。当模型参数超过约 8200 亿, 或训练数据超过约 300 万亿 Token (已超过公开可用人类文本总量的估计 [3]) 时, **再多的参数或数据也无法弥补 0.1 的质量差距**, 质量成为不可替代的资源。该结论属于远超观测范围的外推, 应理解为趋势判断; 但它从模型层面解释了“数据墙”下高质量数据的战略价值。

图 5.6(b) 给出等价增幅对质量映射强度 s_Q 与基线质量的敏感性: $s_Q = 1.5$ 时等价增幅升至 63.2% (参数) 与 101.4% (数据); 当基线质量已高 ($Q = 0.8$) 且 $s_Q = 1.5$ 时, 质量提升触及上限 $Q = 1$, 等价增幅回落至 24.9% 与 37.1%。

注意, 上述等价是“Loss 意义上的等价”, 并未计入提升质量所需的算力。“同样多花一份算力, 投向参数还是投向质量更划算”取决于单位算力的边际收益之比, 这正是问题三 KKT 条件 (式 (6.9)) 所刻画的内容。




图 5.6 质量提升 0.1 的等价资源增幅 (a) 及其对映射强度的敏感性 (b)

5.6.3 领域之间的替代与互补

由问题一 Scheffé 交互项的 bootstrap 结果 (§4)，136 个领域对中有 75 对为稳定互补、没有稳定替代关系。结合广义标度律，可以给出领域 i, j 间的**替代弹性**判据：在参考配比处，若 $\partial^2 R / \partial p_i \partial p_j < 0$ ，则同时增加两个领域的份额比分别增加更有利（互补）；反之则为替代。由于配比项以 $e^{\theta R}$ 乘在可约损失上，这种互补关系在所有规模上成比例保持，其绝对价值随可约损失的缩小而缩小。

5.7 模型检验

5.7.1 外部验证

冻结 B1 参数后，对 B2、B4、B5、B10 直接做预测（图 5.7）。跨模型族记录 B4 与文献数据 B5 的 Spearman 系数分别达 0.983 与 0.959，说明**标度律对新模型族保持了正确的排序**；B4、B5 的 RMSE 为 0.293、0.198，绝对偏差主要来自不同模型族的分词器与验证集差异，体现为不可约项 E 的平移。半合成族外轨迹 B2 的 RMSE 较大 (1.243)，Spearman 为 0.788，存在系统性的校准差。B10 为按标度律估算的 Loss (RMSE 0.001)，只作量级对照，不计为独立证据。

5.7.2 质量响应的压力测试

B7 主网格中 Loss 随质量总体下降（中位数由 $Q = 0.1$ 时的 2.76 降至 $Q = 1$ 时的 2.39），与 GQ2 方向一致；B6 为 B7 的子集，其质量响应与 B7 一致。半合成扩展网格 B8 则在大规模与远端外推区出现“质量越高 Loss 越高”的反向响应和 $L = 0.5$ 截断地板，地板记录比例随参数规模增至 38.3%（图 5.8）。这类响应违背基本常识，因此 B8 不参与模型选择，只用于标出外推风险区。




图 5.7 经典标度律在 B2、B4、B5、B10 上的外部验证

5.7.3 百亿参数以上的外推

B1/B7 的观测支持域为 $N \in [0.07, 12]B$ 、 $D \in [10, 300]B$ 。B9 给出百亿参数以上模型的规模信息，其规模已超出支持域 1–3 个数量级；B10 的 Loss 是按标度律估算的，与本文预测高度吻合（RMSE 0.001），但只能说明二者使用了相近的外推公式，不能作为外推正确的证据。因此本文对超出支持域的预测统一标记为外推：参数—数据项的外推有 Chinchilla 系列研究的独立支持 [2, 19]，可信度较高；质量项与配比项的外推依赖假设 5.2 与假设 5.3，其中配比项的尺度不变性已在三个数量级上得到检验。

5.8 问题二小结

问题二主要结论

- (1) 提出同时包含 $N, D, Q, \mathbf{p}$ 的广义标度律 $L = E + [An^{-\alpha} + Bd^{-\beta} + c_Q(1-Q)^{\nu_Q}]e^{\theta R(\mathbf{p})}$ ，在 $Q = 1$ 、 $\mathbf{p} = \mathbf{p}_{\text{ref}}$ 时严格退化为经典形式，并保证 $L > E$ 。
- (2) 经典项的留一规模 RMSE 为 1.47×10^{-4} ，参数—数据可分性得到数据坍塌检验的




图 5.8 B7 主质量网格与 B8 扩展网格的质量响应及截断地板比例

支持；质量项选择加性惩罚 GQ2（成块验证 RMSE 0.072，较 GQ1 降低 38.7%），质量每提高 0.1 使 Loss 降低约 0.036。

- (3) 配比效应的绝对强度随规模下降 69%，但其相对可约损失的系数 $\theta \approx 0.085$ 在 1M–1B 三个数量级上保持稳定，检验了“配比效应尺度不变”假设；近优配比可使可约损失降低约 17.6%。
- (4) 质量提升 0.1 等价于参数量增加 37.3% 或数据量增加 56.9%；给出了替代存在的充要条件与临界规模闭式解：当 $N \gtrsim 820B$ 或 $D \gtrsim 3 \times 10^{14}$ Token 时，质量差距无法再由规模弥补。领域之间以互补关系为主。

6 问题三：算力约束下的资源联合优化与结构性转移

6.1 优化模型的建立

6.1.1 决策变量与目标函数

以问题二的广义标度律 (5.14) 为目标函数。决策变量为参数量 N 、训练 Token 数 D 、处理后数据质量 Q_A 与领域配比 $\mathbf{p}$ ；预算 C 、上下文长度 L_{ctx} 、质量成本函数 g 与质量映射斜率 s_Q 为外生情景变量。

配比的处理。由定理 5.1(4)，对任意固定 $\mathbf{p}$ ，Loss 可写成 $E + \Phi(N, D, Q_A) e^{\theta R(\mathbf{p})}$ ，而三类成本都与 $\mathbf{p}$ 无关。因此联合优化可以**分两步精确求解**：

$$\min_{N, D, Q_A, \mathbf{p}} L = E + \left[\min_{\mathbf{p} \in \mathcal{P}} e^{\theta R(\mathbf{p})} \right] \cdot \left[\min_{(N, D, Q_A) \in \Omega(C)} \Phi(N, D, Q_A) \right], \quad (6.1)$$

其中 $\mathcal{P}$ 为问题一的配比支持域 (4.15)， $\Omega(C)$ 为预算可行域。第一步的解就是问题一的近优配比 $\mathbf{p}^*$ ，与预算无关；第二步在 $\mathbf{p}$ 固定下优化 (N, D, Q_A) 。由此得到一个重要推论：**最优领域配比不随预算发生结构性转移，结构性转移只可能发生在规模与质量之间**。严格地说，基线质量 $Q_0(\mathbf{p}) = \mathbf{p}^\top \mathbf{q}$ 也依赖配比，但 $Q_0(\mathbf{p}^*) = 0.5454$ 与 $Q_0(\mathbf{p}_{\text{ref}}) = 0.5390$ 仅差 0.006；为保守起见，第二步统一取 $Q_0 = 0.5390$ 。下文先在 $\mathbf{p}_{\text{ref}}$ 下求解 (N^*, D^*, Q_A^*) ，再乘以配比因子得到 $\mathbf{p}^*$ 下的最优 Loss。

6.1.2 算力成本与约束

三类开销为

$$C_{\text{train}} = 6ND, \quad C_Q = D[g(Q_A) - g(Q_0)]_+, \quad C_{\text{attn}} = \eta NDL_{\text{ctx}}, \quad \eta = 2 \times 10^{-4}, \quad (6.2)$$

其中 $6ND$ 为训练算力的标准近似 [1, 2]；自注意力的计算量随序列长度增长 [21, 22]，在总 Token 数固定时，每个 Token 的附加开销近似正比于 L_{ctx} 。质量成本采用附录 B 给出的三类函数：

$$g_{\text{exp}}(Q) = 10^7 e^{6Q}, \quad g_{\text{pow}}(Q) = 5 \times 10^9 Q^4, \quad g_{\text{log}}(Q) = 2 \times 10^9 \ln(1 + 10Q). \quad (6.3)$$

三者的差异在于边际成本的形状：指数型的边际成本随质量加速上升（“越往后越贵”），幂函数型在低质量区极便宜而高质量区陡增，对数型则前期投入大、后期几乎免费。优化模型为

$$\begin{aligned} \min_{N, D, Q_A} \quad & \Phi(N, D, Q_A) = An^{-\alpha} + Bd^{-\beta} + c_Q(1 - Q_{\text{eff}})^{\nu_Q} \\ \text{s.t.} \quad & (6 + \eta L_{\text{ctx}})ND + D[g(Q_A) - g(Q_0)]_+ \leq C, \\ & N_{\min} \leq N \leq N_{\max}, \quad D_{\min} \leq D \leq D_{\max}, \quad Q_0 \leq Q_A \leq Q_{\text{sat}}, \end{aligned} \quad (6.4)$$

其中 $Q_{\text{sat}} = \min\{1, Q_0 + (1 - \varepsilon - Q_0)/s_Q\}$ 使有效质量不超过 1。为区分“有数据支撑的结论”与“外推结论”，设置两层可行域：严格支持域 $N \in [0.07, 12]\text{B}$ 、 $D \in [10, 300]\text{B}$ （B1/B7 的观测范围）与扩展域 $N \in [0.07, 10^4]\text{B}$ 、 $D \in [0.1, 3.6 \times 10^4]\text{B}$ ；主结果在扩展域中求解，并对每个解标注支持状态。

6.2 上下文长度的临界值与可行取值

由式 (6.2)，注意力开销与基础训练开销之比为

$$\frac{C_{\text{attn}}}{C_{\text{train}}} = \frac{\eta L_{\text{ctx}}}{6}, \quad (6.5)$$

它与 N, D, C 均无关。令其等于 1，得到两者相当的临界上下文长度

$$L_{\text{ctx}}^{\text{crit}} = \frac{6}{\eta} = \frac{6}{2 \times 10^{-4}} = 30000 \text{ Token}. \quad (6.6)$$

L_{ctx} 的可行取值依据 C7：其 45 条经核验的模型记录给出 2048、4096、8192、32768、131072 五档上下文窗口，对应比值分别为 0.068、0.137、0.273、1.092、4.369。前三档注意力开销不足训练开销的 30%，后两档已越过临界点：32K 时注意力开销略超训练开销，128K 时是训练开销的 4.4 倍。由于比值与预算无关， L_{ctx} 的作用等价于把单位参数—Token 的训练成本从 6 放大到 $6 + \eta L_{\text{ctx}}$ ，即**有效预算**缩小为 $C/(1 + \eta L_{\text{ctx}}/6)$ 。

6.3 模型求解

6.3.1 解析降维

记 $\Delta g = [g(Q_A) - g(Q_0)]_+$ ，总成本可写成 $C_{\text{tot}} = D[(6 + \eta L_{\text{ctx}})N + \Delta g(Q_A)]$ 。由于 $\partial \Phi / \partial D < 0$ ，最优解必然用尽预算（或触及 D_{max} ），于是

$$D^*(N, Q_A) = \min \left\{ D_{\text{max}}, \frac{C}{(6 + \eta L_{\text{ctx}})N + \Delta g(Q_A)} \right\}, \quad (6.7)$$

三维约束问题化为 $(\log N, Q_A)$ 上的二维有界问题。在 $Q_A = Q_0$ 且无边界约束时，还有闭式解

$$n^* = \left(\frac{\alpha A}{\beta B} \right)^{\frac{1}{\alpha+\beta}} \bar{C}^{\frac{\beta}{\alpha+\beta}}, \quad d^* = \frac{\bar{C}}{n^*}, \quad \bar{C} = \frac{C}{(6 + \eta L_{\text{ctx}}) \times 10^{18}}, \quad (6.8)$$

用作初值与正确性核对。图 6.1 展示了 4096 上下文、 10^{19} FLOPs 下降维后的目标景观：三种成本函数都形成一条“参数—质量”相互替代的谷地，但谷底位置截然不同——指数成本得到内点解 $Q_A^* = 0.671$ ，幂函数成本停在下界 $Q_A^* = Q_0$ ，对数成本则直达上界 $Q_A^* = 1$ 。

6.3.2 求解算法

完整求解流程见算法 1。粗网格保证全局覆盖，多起点 SLSQP 负责局部精化，预算追踪保证路径连续，完整三维非线性规划与加密网格用于独立核对。




图 6.1 低预算 (10^{19} FLOPs, $L_{\text{ctx}} = 4096$) 下三类质量成本的降维目标景观

算法 1 算力约束下的资源配置与结构转移识别

输入: 广义标度律参数、 Q_0 、预算网格 $\mathcal{C}$ (10^{19} – 10^{24} , 61 点)、上下文集合 $\mathcal{L}$ 、成本函数集合 $\mathcal{G}$

输出: 各情景最优解 (N^*, D^*, Q_A^*)、成本份额、活跃约束集合与转移点

- 1: **for all** $g \in \mathcal{G}$, $L_{\text{ctx}} \in \mathcal{L}$ **do**
- 2: **for all** $C \in \mathcal{C}$ (升序) **do**
- 3: 在 $(\log N, Q_A)$ 粗网格上按式 (6.7) 计算目标, 剔除不可行点
- 4: 取最优的 20 个网格点及上一预算的最优解为初值, 执行 SLSQP 局部精化
- 5: 对三档主预算用完整三维 NLP 与加密网格独立复核
- 6: 记录成本份额、活跃约束集合 $\mathcal{A}(C)$ 与支持状态
- 7: 比较相邻预算的 $\mathcal{A}(C)$ 识别主要转移, 二分加密至 $\Delta \log_{10} C \leq 0.01$
- 8: 对配置弹性作分段线性拟合, 识别次要转移
- 9: 500 组参数 bootstrap 传播不确定性; 200 条抽样路径估计转移出现概率

6.3.3 KKT 条件与资源竞争

设预算约束活跃、乘子为 $\mu > 0$, 质量上下界的乘子为 $\underline{\lambda}, \bar{\lambda} \geq 0$ 。KKT 条件给出

$$\frac{-\partial\Phi/\partial N}{\partial C_{\text{tot}}/\partial N} = \frac{-\partial\Phi/\partial D}{\partial C_{\text{tot}}/\partial D} = \mu, \quad -\frac{\partial\Phi}{\partial Q_A} - \mu Dg'(Q_A) + \underline{\lambda} - \bar{\lambda} = 0, \quad (6.9)$$

其中 $\partial C_{\text{tot}}/\partial N = (6 + \eta L_{\text{ctx}})D$, $\partial C_{\text{tot}}/\partial D = (6 + \eta L_{\text{ctx}})N + \Delta g$ 。式 (6.9) 的经济含义是: **最优时每一单位算力无论投向参数、数据还是质量, 带来的 Loss 降幅都相等**。据此, 质量投入有三种状态:

- **未启动** ($Q_A^* = Q_0$, $\underline{\lambda} > 0$): 质量的单位算力收益 $-\partial\Phi/\partial Q_A/(Dg'(Q_0))$ 低于规模的单位算力收益 μ , 全部算力用于 N, D ;
- **竞争** ($Q_0 < Q_A^* < Q_{\text{sat}}$, $\underline{\lambda} = \bar{\lambda} = 0$): 三种资源的单位算力收益相等;

- **饱和** ($Q_A^* = Q_{\text{sat}}$, $\bar{\lambda} > 0$): 质量已达上限, 新增算力重新全部流向规模扩张。

预算增大时 D 增大, 质量的总收益 $D \cdot (-\partial\Phi/\partial Q_A)$ 与数据量成正比地放大, 而规模的边际收益按幂律递减, 因此质量投入必然经历“未启动 $\rightarrow$ 竞争 $\rightarrow$ 饱和”的顺序。

6.3.4 结构性转移的数学定义与识别

定义 6.1 (结构性转移) 固定 (g, L_{ctx}, s_Q) , 记预算 C 下最优解的活跃约束集合为

$$\begin{aligned} \mathcal{A}(C) &= \{c \in \mathcal{K} : c \text{ 在最优解 } x^*(C) \text{ 处取等号}\}, \\ \mathcal{K} &= \{Q_A = Q_0, Q_A = Q_{\text{sat}}, N = N_{\min/\max}, D = D_{\min/\max}, C_{\text{tot}} = C\}. \end{aligned} \quad (6.10)$$

若存在 $C^\dagger$ 使 $\mathcal{A}(C^{\dagger-}) \neq \mathcal{A}(C^{\dagger+})$, 称 $C^\dagger$ 为**主要结构性转移点**, 此时最优策略的**类型**发生质变 (如质量投入从未启动变为启动)。在 $\mathcal{A}(C)$ 不变的区段内, 定义配置弹性

$$\theta_x(C) = \frac{d \ln x^*(C)}{d \ln C}, \quad x \in \{N, D, Q_A - Q_0\}, \quad (6.11)$$

若 θ_x 在某点发生跳变 (分段线性拟合相对单一直线的 BIC 改善 ≥ 10 [23], 且两侧斜率差 ≥ 0.15), 称为**次要结构性转移**, 此时策略类型不变但资源增长的主次关系改变。只有在至少 70% 的参数抽样路径中都出现的转移才认定为**稳定转移**。

识别方法: 在 61 个对数等距预算点上追踪 $\mathcal{A}(C)$, 发现变化后二分加密至 $\log_{10} C$ 区间宽度 ≤ 0.01 ; 次要转移在活跃集不变的区段内用分段回归定位。

6.4 求解结果

6.4.1 三档预算下的最优配置

以 $L_{\text{ctx}} = 4096, s_Q = 1$ 为主情景, 三档预算的最优配置见表 6.1。其中 L_{ref}^* 为参考配比下的最优 Loss, $L_\star^*$ 为采用近优配比 $p^\star$ 后的最优 Loss (由式 (6.1), $L_\star^* = E + (L_{\text{ref}}^* - E) \times 0.824$)。

成本函数的影响集中在低预算。 在 10^{19} FLOPs, 三种成本函数给出三种截然不同的策略: 对数成本前期昂贵、后期平坦, 一旦投入就直接做到最高质量, 用 32.1% 的预算提质, 同时把数据量压到 2.95B; 指数成本选择中间质量 0.671; 幂函数成本则完全不提质, 把算力全部投给规模。到 10^{22} 与 10^{24} FLOPs, 三种成本函数都达到质量上限, 最优参数量、数据量与 Loss 趋于一致 (10^{24} 时 Loss 差异小于 5×10^{-4}), **成本函数的形状不再重要**。

质量在高预算下是“必选项”, 而其算力占比很小。 10^{22} FLOPs 时, 把质量提升到上限只占用 3.1%–10.8% 的预算, 到 10^{24} FLOPs 更降至 0.4%–1.7%。这是因为质量成本按单位 Token 计费, 而训练成本按“参数 $\times$ Token”计费, 模型越大, 质量处理的相对成本越低——这与问题二“规模越大、质量越值钱”的结论相互印证。

数据—参数比随预算上升。 D^*/N^* 从 10^{22} 的 42–56 升至 10^{24} 的 91–95, 显著高于 Chinchilla 经验值 20[2]。原因是本文 B1 拟合的 $\alpha = 0.340 > \beta = 0.280$: 参数项衰减更快, 最优策略更偏向数据, 且 $N^* \propto C^{0.452}$ 、 $D^* \propto C^{0.548}$ 使数据—参数比随预算按 $C^{0.097}$ 增长。

表 6.1 $L_{\text{ctx}} = 4096$ 下三档预算的最优资源配置

成本	预算/FLOPs	N^*/B	D^*/B	D^*/N^*	Q_A^*	质量份额	L_{ref}^*	$L_\star^*$	支持状态
指数	10^{19}	0.259	4.82	19	0.671	14.8%	3.1690	2.9082	单分量外推
	10^{22}	5.449	244.3	45	1.000	9.2%	2.1549	2.0729	观测支持
	10^{24}	39.58	3653.8	92	1.000	1.4%	1.9160	1.8761	外推
幂函数	10^{19}	0.215	6.81	32	0.539	0.0%	3.1796	2.9170	单分量外推
	10^{22}	5.558	235.4	42	1.000	10.8%	2.1563	2.0741	观测支持
	10^{24}	39.71	3631.3	91	1.000	1.7%	1.9161	1.8762	外推
对数	10^{19}	0.337	2.95	9	1.000	32.1%	3.1181	2.8663	单分量外推
	10^{22}	5.048	281.6	56	1.000	3.1%	2.1498	2.0687	观测支持
	10^{24}	39.13	3732.4	95	1.000	0.4%	1.9157	1.8759	外推

配比带来与预算无关的比例收益。采用 $\mathbf{p}^*$ 使可约损失在所有预算下都降低 17.6%: Loss 在 10^{19} 、 10^{22} 、 10^{24} FLOPs 下分别降低约 0.26、0.08、0.04。按 $R(\mathbf{p}^*)$ 的 95% 区间, 10^{22} FLOPs 下的 Loss 变化量在 $[-0.121, +0.004]$ 之间 (最多降低 0.121, 最坏升高 0.004)。

领域 Token 分配。最优总 Token 数按 $D_i = p_i D^*$ 分解到 17 个领域。以指数成本、 10^{22} FLOPs ($D^* = 244.3\text{B}$) 为例, 采用 $\mathbf{p}^*$ 时专利背景、生医摘要、技术问答、议会文本分别分配 59.1、46.2、36.4、25.3B Token, 学术论文、代码、法律、生物医学全文不再分配; 若出于稳健考虑采用 $\mathbf{p}_{\text{ref}}$, 则各领域在 0.5–29.2B 之间较为均衡地分配。完整分配表见支撑材料。

6.4.2 连续预算路径与结构性转移

图 6.2 给出 10^{19} – 10^{24} FLOPs 的连续最优路径, 图 6.3 给出对应的算力份额。通过稳定性检验的结构性转移见表 6.2。

结果显示了清晰的**三阶段结构性转移**, 以幂函数成本最为完整:

- (1) **规模优先期** ($C < 1.34 \times 10^{19}$): 质量投入未启动, 全部算力用于参数与数据;
- (2) **质量—规模竞争期** ($1.34 \times 10^{19} \leq C < 6.69 \times 10^{19}$): 质量投入启动并快速上升, 质量份额峰值达 41.4%; 这一阶段数据量几乎停滞在 6–8B, 新增算力主要在参数与质量之间分配;
- (3) **质量饱和、规模重新主导期** ($C \geq 6.69 \times 10^{19}$): 质量达到上限, 质量份额被持续增长的训练成本稀释 (10^{24} 时降至 0.4%–1.7%, 基础训练份额回升至 87% 左右), N^* 、 D^*




图 6.2 $L_{\text{ctx}} = 4096$ 下最优质量 (a)、参数量 (b) 与数据量 (c) 随预算的变化




图 6.3 $L_{\text{ctx}} = 4096$ 下三类算力开销的份额随预算的变化

表 6.2 $L_{\text{ctx}} = 4096$ 下的稳定结构性转移

成本	类型	转移事件	临界预算/FLOPs	95% 区间 ($\log_{10} C$)	出现概率
幂函数	主要	质量投入启动 (Q_0 下界失效)	1.34×10^{19}	[19.04, 19.21]	1.00
	次要	质量增量弹性断点	4.22×10^{19}	—	1.00
	主要	质量达到饱和 (Q_{sat} 上界激活)	6.69×10^{19}	[19.63, 20.38]	1.00
	次要	参数量、数据量弹性断点	1.10×10^{20}	—	1.00
指数	次要	质量增量弹性断点	9.09×10^{19}	—	1.00
	主要	质量达到饱和	1.23×10^{20}	[19.79, 20.63]	1.00
	次要	数据量弹性断点	2.37×10^{20}	—	1.00
对数	—	起点即饱和，无新转移	—	—	—

恢复幂律增长。

指数成本在 10^{19} 时已处于竞争期，于 1.23×10^{20} 饱和，质量份额峰值 33.1%；对数成本在整个区间都处于饱和期。这与题目“收入低时先顾温饱、收入高时追求品质”的类比完全一致：**低预算先保规模，中等预算质量与规模竞争，高预算质量成为标配而规模重新成为主要增长方向。**

图 6.4 给出各转移预算的 bootstrap 分布。所有 8 个稳定转移的出现概率均为 1；主要转移的定位极为精确（幂函数质量启动的 95% 区间仅为 $\log_{10} C \in [19.04, 19.21]$ ），饱和点的不确定性稍大，主要来自质量参数 c_Q, ν_Q 的估计误差。

6.4.3 上下文长度的敏感性

在 C7 的五档可行上下文上重新求解，最优 Loss 相对 2048 上下文的增量见图 6.5，最优配置的变化见图 6.6。

- (1) **临界点前后影响截然不同。**在 $L_{\text{ctx}} \leq 8192$ 时，Loss 增量在低预算下不超过 0.036、在 10^{22} FLOPs 以上不超过 0.012；越过 30000 后惩罚迅速扩大——32768 上下文下 10^{19} FLOPs 的增量已达 0.12–0.14，131072 上下文下， 10^{19} 、 10^{22} 、 10^{24} FLOPs 的 $100\Delta L^*$ 分别为 32.7–36.0、12.4–12.6 和 6.3。**预算越低，长上下文越“奢侈”，高预算能够通过扩大规模部分吸收这一开销。**
- (2) **长上下文主要挤压数据量。**131072 上下文下 N^* 降至 2048 基准的 39%–56%， D^* 降至 31%–60%。低预算幂函数成本下 D^* 降幅最大（至 31%），同时 Q_A^* 由 0.539 升至 0.668；指数成本下 Q_A^* 由 0.666 升至 0.778——**当规模变贵时，最优策略用质量替代规模。**




图 6.4 稳定结构性转移点的 bootstrap 区间估计




图 6.5 上下文长度引起的最优 Loss 增量 (a-c) 与注意力/训练开销比 (d)




图 6.6 上下文长度对最优参数量 (a)、数据量 (b) 与质量 (c) 的影响

(3) 上下文不改变转移机制。 L_{ctx} 只改变有效预算，三阶段结构性转移在各档上下文下依然存在，只是转移点随有效预算缩小而向高预算方向平移。

6.5 模型检验与敏感性分析

6.5.1 数值验证

对全部中心解逐项回代：约束违反量最大 4.1×10^{-16} ；二维降维解与完整三维 NLP 的相对 Loss 差最大 4.4×10^{-14} ；与加密网格的相对差 2.1×10^{-16} ；领域 Token 求和误差 1.9×10^{-16} ；同种子重复运行结果完全一致。图 6.7 以质量处于内点、局部最优风险最大的“指数成本、 10^{19} FLOPs”情景为例：20 个网格起点全部在 6–11 次迭代内收敛到同一最优解，最终相对 Loss 差在 1.5×10^{-13} 以内。此外，全部中心解均满足“预算增大 Loss 不增”“上下文增长 Loss 不降”等单调性检验。

6.5.2 参数不确定性与关键假设敏感性

用问题二的 500 组联合 bootstrap 参数重新求解， 10^{22} 与 10^{24} FLOPs 下最优 Loss 的 95% 区间宽度不超过 1.2×10^{-4} ； 10^{19} FLOPs 下宽度约 0.03（幂函数成本最宽），主要来自质量参数的不确定性。关键假设的敏感性（共 234 个情景）见图 6.8：

- **质量映射斜率 s_Q** 影响最大： $s_Q = 0.5$ 使 10^{22} 、 10^{24} FLOPs 的 Loss 上升 0.085，因为此时质量提升只能部分传导到有效质量；
- **质量成本幅度与形状**的 $\pm 20\%$ 扰动只影响低预算（最大 0.053），高预算下几乎无影响；
- **注意力系数 η** 的 $\pm 20\%$ 扰动影响不超过 0.005；
- **严格支持域**使 10^{24} FLOPs 的 Loss 上升约 0.177，这是因为最优规模远超观测范围、被边界截断，说明高预算结论本质上依赖标度律外推。




图 6.7 多起点寻优轨迹 (a) 与相对 Loss 差的收敛过程 (b)




图 6.8 $L_{\text{ctx}} = 4096$ 下关键假设对最优 Loss 的影响 ($100\Delta L^*$)

6.6 问题三小结

问题三主要结论

- (1) 由广义标度律的乘性配比结构证明了配比与规模—质量决策的可分性：最优配比 p^* 与预算无关，可使所有预算下的可约损失降低约 17.6%。
- (2) 注意力与训练开销相当的临界上下文长度为 $L_{\text{ctx}}^{\text{crit}} = 6/\eta$ ，即 30000 Token；C7 的 32K、128K 两档已越过临界点，128K 上下文在 10^{19} FLOPs 下使最优 Loss 上升约 0.33–0.36。
- (3) 以 4096 上下文、指数成本为例，三档预算的最优参数数量分别为 0.26、5.45、39.6B，

最优 Token 数分别为 4.8、244、3654B，最优质量分别为 0.671、1.0、1.0；最优 Loss 为 3.169、2.155、1.916，采用 $\mathbf{p}^*$ 后为 2.908、2.073、1.876。

- (4) 以 KKT 活跃约束集合的变化定义结构性转移，识别出“规模优先 $\rightarrow$ 质量—规模竞争 $\rightarrow$ 质量饱和、规模主导”的三阶段转移；幂函数成本下两个主要转移点分别为 1.34×10^{19} FLOPs 与 6.69×10^{19} FLOPs，出现概率均为 1。成本函数形状只在低预算下重要。

7 问题四：技术演进分析与能力前沿预测

7.1 口径界定与数据准备

7.1.1 四项口径

- (1) **综合能力的度量**。采用 Open LLM Leaderboard v2[24] 的六项官方归一化得分 (IFEval、BBH、MATH Lvl 5、GPQA、MuSR、MMLU-PRO) 的算术平均

$$S_i = \frac{1}{6} \sum_{k=1}^6 S_{ik}, \quad S_{ik} \in [0, 100], \quad (7.1)$$

其中各项已按官方规则扣除随机猜测下界 [25]。复算结果与官方 Average 的最大绝对误差为 1.4×10^{-14} 。选用等权平均的理由是：六项任务覆盖指令遵循、推理、数学、专业知识与多步推理，等权可避免人为偏好；作为敏感性分析，另构造六维秩正态平衡分。

- (2) **开源筛选口径**。入选模型须在 C2 或高置信 C4 记录中有**开放权重**证据；严格敏感性分析进一步要求许可证允许研究与复现（许可证缺失不视为无限制）。闭源模型与仅开放 API 的模型不入选。
- (3) **模型类型**。区分 pretrained（预训练基础模型）、posttrained（chat/finetuned，经对话指令或监督微调）、merge（权重合并）与 excluded。**贡献分解只使用 pretrained 及持续预训练模型**，以免把微调收益或基座算力重复计入预训练规模；posttrained 层只有 6 条合格算力记录，不足以独立分解，仅作覆盖说明。
- (4) **时间轴口径**。主分析按排行榜**提交日期**计时（有效范围 2024-06-08 至 2025-03-13），因为它对所有记录统一可得；以模型发布日期作为敏感性分析。

7.1.2 数据清洗与证据分层

数据使用方式见表 7.1，清洗与复现结果见图 7.1。

C8 逐任务聚合分析。按官方规则，BBH 的每个子任务先扣除随机猜测下界再等权平均：


$$z_{ij} = \max \left\{ 0, \frac{s_{ij} - l_j}{1 - l_j} \right\}, \quad \hat{S}_i^{\text{BBH}} = \frac{100}{|J_i|} \sum_{j \in J_i} z_{ij}, \quad (7.2)$$

其中 s_{ij} 为模型 i 在子任务 j 上的原始准确率， l_j 为随机下界。在 1786 个可比模型中，重算值与官方值精确一致的有 1736 个 (97.2%)，证明汇总表的 BBH 得分可由逐任务数据复现。MATH Lvl 5 仅 737/1782 精确一致，且偏差系统性地位于对角线下方，推测官方聚合使用了未公开的子集过滤规则，故 MATH 的逐任务结果只作审计参考，不影响式 (7.1) 的主表。


表 7.1 问题四的数据与用途

数据	规模	用途与处理
C1 / C2	4576 条，版本去重后 4546 条	六任务能力、提交日期、模型类型与许可证；C2 为主表，C1 核验分数
C3	26 条论文/报告记录	2023–2024 长窗口的方向性检验
C4	3523 条，接受匹配 66 条	训练算力、数据量、开放权重证据；按名称、组织、族、版本、参数量五项匹配，最终 41 条进入确认性前沿（7 个月、13 个模型族）
C5 / C6	43 / 75 条	Loss–Benchmark 桥接（C5 为 C6 子集，只用 C6 拟合一次）
C7	45 条	上下文长度可行取值（问题三）
C8	1863 个模型目录	逐任务重算：BBH 子任务聚合

(a)



(b)



(c)




图 7.1 数据筛选过程 (a) 与 C8 逐任务重算：BBH (b)、MATH Lvl 5 (c)

7.2 Loss–Benchmark 桥接模型

7.2.1 模型形式

Loss 与下游能力总体负相关，但二者并非一一对应：相同预训练 Loss 可能对应不同的下游能力 [26]，离散的评测指标还会放大或掩盖连续的 Loss 变化 [27, 28]。为保证预测落在 $[0, 100]$ ，先作有界 logit 变换

$$g_{\epsilon}(S) = \text{logit} \frac{S + \epsilon}{100 + 2\epsilon}, \quad g_{\epsilon}^{-1}(y) = (100 + 2\epsilon)\sigma(y) - \epsilon, \quad \epsilon = 0.5, \quad (7.3)$$

再建立单调桥接

$$g_{\epsilon}(S_{im}) = h_m(\ln L_i) + e_{im}, \quad h'_m(\cdot) \leq 0, \quad (7.4)$$

h_m 在常数、单调线性、单调样条、保序回归四类候选中选择。C6 按可比性分级：高可比记录权重为 1，中可比记录权重为 0.25。以**来源族留一**交叉验证（12 个来源族）评价，按一倍标准误原则选最简模型。

7.2.2 选择结果




图 7.2 Loss-Benchmark 桥接：候选模型比较 (a)、Average 留族预测 (b) 与七类目标的桥接误差 (c)

结果见图 7.2。对综合能力 Average，单调样条的留族 MAE 最低 (9.38)，单调线性为 10.22，落在一倍标准误阈值 (10.70) 以内，故选择更简单的单调线性桥接；它优于常数基线 (11.38)，RMSE 为 12.39。在六项子任务中，BBH、MuSR、MMLU-PRO 的桥接优于常数基线，IFEval、MATH、GPQA 则未能稳定优于常数，说明**指令遵循与高难度数学、专业问答能力不能由预训练 Loss 可靠预测**，这与 Loss 之外的后训练因素主导这类能力的认识一致 [29, 30]。因此只用 Average 承担主结论。桥接的完整支持区间为 $\text{Loss} \in [1.65, 2.84]$ ，其中高可比范围为 $[2.093, 2.598]$ 。

7.2.3 问题三方案的能力映射与误差影响

结果见表 7.2 与图 7.3。三种成本函数在中高预算下的映射能力几乎相同 (差异 < 0.2 分)，与问题三“高预算下成本形状不再重要”一致。预算每提高两个数量级 ($10^{22} \rightarrow 10^{24}$)，综合能力约提高 6 分。若采用近优配比 p^* ，按中心桥接换算， 10^{22} 、 10^{24} FLOPs 的综合能力约可再提高 1.9 分和 1.3 分。

映射误差的影响。把问题三的 Loss 抽样与桥接的来源族 bootstrap 配对传播，得到三组区间宽度 (图 7.9(b))：仅上游 Loss 不确定性的 80% 宽度中位数约为 0.00 分 (最大 0.09)，仅桥接不确定性为 9.17 分，联合为 9.17 分。**映射误差是能力结论不确定性的绝对主导来**




图 7.3 问题三 45 个最优方案的 Loss 到综合能力映射及桥接支持区间

表 7.2 $L_{ctx} = 4096$ 下问题三最优方案的能力映射（参考配比）

质量成本	预算/FLOPs	最优 Loss	能力中位数	80% 区间	桥接支持
指数	10^{19}	3.169	3.00	[1.68, 6.26]	范围外
	10^{22}	2.155	13.39	[9.37, 18.68]	高可比
	10^{24}	1.916	19.51	[14.02, 26.56]	扩展支持
幂函数	10^{19}	3.180	2.97	[1.63, 6.24]	范围外
	10^{22}	2.156	13.36	[9.35, 18.63]	高可比
	10^{24}	1.916	19.51	[14.02, 26.56]	扩展支持
对数	10^{19}	3.118	3.22	[1.83, 6.63]	范围外
	10^{22}	2.150	13.49	[9.46, 18.80]	高可比
	10^{24}	1.916	19.52	[14.03, 26.57]	扩展支持

源，比优化器与标度律参数误差大两个数量级。因此：（1）能力的**相对比较**（不同成本、不同预算之间）是可靠的，因为同一桥接的误差高度正相关；（2）能力的**绝对水平**只能以约 ± 5 分的精度解读；（3）低预算方案的 Loss (> 3.1) 超出桥接支持上界，其能力值仅作量级参考。

7.3 能力前沿的动力学模型

7.3.1 条件分位前沿

能力前沿关心的是“给定算力与时点，较优的模型能达到多高”，而不是平均水平，因此采用 $\tau = 0.90$ 条件分位回归 [31]。令 $Y_i = g_\epsilon(S_i)$, $x_i = \log_{10} C_i$ (训练算力，标准化为 $\tilde{x}_i$)，建立

$$Q_\tau(Y_i | x_i, t_i) = \beta_0 + \beta_C \tilde{x}_i + a_{m(i)}, \quad \beta_C \geq 0, \quad (7.5)$$

其中 a_m 为提交月份 m 的**非规模技术状态**，吸收架构、数据工程、优化方法等不随算力度量的因素。主模型只放入训练算力 C ，而不同时放入 N 与 D ，以避免 $C \approx 6ND$ 引起的机械共线。

7.3.2 技术状态的动力学方程

技术状态按局部线性趋势演进 [32]：

$$a_m = a_{m-1} + v_{m-1} + \eta_m, \quad v_m = v_{m-1} + \zeta_m, \quad (7.6)$$

v_m 为技术进步速度。数值上以平滑 pinball 损失加一阶、二阶差分惩罚实现，平滑强度 λ 与未来斜率权重 ρ 只由 3、6 个月滚动起点回测选择（每一折只用预测时点以前的数据）。最终 $\lambda = 10^4$ 、 $\rho = 0$ ，标准化算力系数 $\hat{\beta}_C = 0.685 > 0$ 。三条分位 (0.85, 0.90, 0.95) 若交叉，则单调重排 [33]。




图 7.4 确认性 pretrained 样本的训练算力与 0.90 能力前沿 (2024-06 与 2025-01)

图 7.4 显示，能力前沿随训练算力呈清晰的上凸增长：在 $\log_{10} C$ 从 21.6 增至 25.0 的范围内，前沿由约 5 分升至约 54 分；观测最高分为 Qwen2.5-72B 的 38.4 分 (7.8×10^{24} FLOPs)。2024-06 与 2025-01 两条前沿曲线几乎重合（最大差 0.0002 分），这已经直观地预示了下一节的分解结论。

7.4 规模扩张与非规模技术进步的贡献分解

7.4.1 Shapley 分解

取确认性面板的首末月份 $t_0 = 2024-06$ 、 $t_1 = 2025-01$ ，以两月训练算力的 0.90 分位 x_0, x_1 代表前沿规模。记 $F(x, t)$ 为式 (7.5) 经逆变换后的能力分。由于模型非线性，“先换规模”与“先换时间”得到的增量不同，采用两因素 Shapley 值 [34] 取两条路径的平均：

$$\Delta_{\text{scale}} = \frac{1}{2} [F(x_1, t_0) - F(x_0, t_0) + F(x_1, t_1) - F(x_0, t_1)], \quad (7.7)$$

$$\Delta_{\text{tech}} = \frac{1}{2} [F(x_0, t_1) - F(x_0, t_0) + F(x_1, t_1) - F(x_1, t_0)], \quad (7.8)$$

二者之和恰为总变化 $F(x_1, t_1) - F(x_0, t_0)$ （数值闭合误差 5.6×10^{-17} ）。贡献占比定义为 $\Delta_{\text{scale}} / (\Delta_{\text{scale}} + \Delta_{\text{tech}})$ 。不确定性以模型族为横截面簇、连续月份为时间块做联合块 bootstrap [35]（1000 次）。

7.4.2 分解结果

表 7.3 2024-06 至 2025-01 能力前沿提升的贡献分解

分解量	中心估计/分	80% 区间	95% 区间	贡献占比
能力总变化	4.618	[2.842, 5.663]	[2.533, 6.686]	100%
规模扩张贡献	4.618	[2.841, 5.664]	[2.533, 6.687]	$\approx 100\%$
非规模技术贡献	-0.0001	[-0.0018, 0.0037]	[-0.0027, 0.0053]	$\approx 0\%$

注：规模贡献占比的 bootstrap 95% 区间为 [99.88%, 100.06%]。




图 7.5 贡献分解的点估计与区间 (a)、规模贡献 (b) 与规模占比 (c) 的 bootstrap 分布

由表 7.3 与图 7.5：2024 年 6 月至 2025 年 1 月，开源 pretrained 模型的 0.90 能力前沿提升 4.62 分，其中**规模扩张贡献约 100%**（规模贡献为正的的概率为 100%），**非规模技术贡献约 0%**，其区间在 ± 0.005 分内且跨零（为正的的概率 0.53）。

这一结论在各种设定下都稳健（图 7.6）：改变能力口径（平衡分）、样本边界（严格许可证、严格算力证据）、时间轴（发布日期）、边界参数 ϵ 与块长，规模贡献始终为正（3.87–11.34 分），非规模贡献始终接近 0（除发布日期口径为 -0.033 外，均在 ± 0.0023 以内）。引入 C3 的 2023–2024 长窗口记录后，控制参数量后的年份系数中心为 -0.034 、为正的的概率 0.41，同样未检出稳定的非规模进步方向。




图 7.6 贡献分解对样本、口径、时间轴与估计参数设定的敏感性

如何理解“非规模贡献约为 0”。这并不意味着架构、数据与训练方法没有进步，而是说明：在本数据窗口内，非规模进步已经“体现”在算力—能力关系之中，没有表现为“同等算力下能力随时间整体抬升”。有三点原因。其一，窗口只有 7 个月，而文献估计的算法进步速度约为“每 8 个月达到同等性能所需的算力减半” [36]，7 个月内的时间效应本就接近检测下限；其二，这一时期开源前沿模型（如 Qwen2.5 系列）的主要提升来自训练 Token 数的大幅增加，这在本文口径下计入了“规模”（ $C \approx 6ND$ 中的 D ）；其三，Open LLM Leaderboard v2 的任务难度高，基础模型在 MATH、GPQA 上普遍接近随机下界，限制了非规模改进的可见度。因此，本文的分解应理解为：**近期开源基础模型的能力前沿提升几乎完全可由训练算力增长解释。**

7.5 算力放缓情景下的能力前沿预测

7.5.1 算力增长趋势

训练算力只使用截止日前、开放权重、证据方法为“直接报告、运算计数或硬件估计”的 C4 记录，由 Benchmark 反推的算力一律排除，避免循环论证 [37]。对近 24 个月的家族

一月份面板取加权 0.90 分位，以稳健局部线性趋势得到截止月的算力端点与增速：

$$x_{C,0} = 25.09 \log_{10} \text{FLOPs}, \quad r_C = 0.759 \log_{10} \text{FLOPs/年 (即每年 5.7 倍)}, \quad (7.9)$$

增速的 bootstrap 区间为 $[0.51, 1.00]$ 。这与 Epoch AI 估计的前沿模型训练算力每年增长 4–5 倍 [38, 39] 处于同一量级。设算力对数增速保留比例为 κ ，则

$$x_C(h; \kappa) = x_{C,0} + \kappa r_C \frac{h}{12}, \quad \kappa \in \{1, 0.5, 0.25\}, \quad (7.10)$$

分别代表延续近期趋势、中度放缓与强度放缓（图 7.7）。未来 h 个月的能力前沿由式 (7.5)、(7.6) 与 (7.10) 联合外推。




图 7.7 开源模型训练算力 0.90 分位的历史趋势与三种增长情景

7.5.2 预测结果与不确定性

每次 bootstrap 抽样同时重估前沿参数、技术状态斜率、算力端点、算力增速与算力测量误差，1000 次抽样中 999 次有效。结果见表 7.4 与图 7.8。

- (1) **算力放缓显著压低能力前沿。**24 个月后，延续趋势情景的前沿中心值为 77.2 分；若算力增速减半，降至 65.7 分；若只保留四分之一，降至 59.2 分。与截止时点的观测最高分 38.4 相比，三种情景下 24 个月的提升幅度分别约为 39、27、21 分。
- (2) **能力由“到达的算力”决定。**中度放缓 24 个月与延续趋势 12 个月到达相同算力 ($10^{25.85}$)，前沿值完全相同 (65.74)；强度放缓 24 个月与中度放缓 12 个月亦然。这是“非规模贡献约为 0”的直接推论：**算力放缓一半，能力前沿的到达时间就推迟一倍。**
- (3) **不确定性较大且随期限扩大。**80% 区间宽度约为 25–33 分，主要来自算力增速的不确定性 (r_C 区间 $[0.51, 1.00]$) 与前沿曲线在观测范围之外的外推。12 个月预测对应的算力已超出历史观测上界，24 个月更属长期外推，预测值应结合区间使用。

表 7.4 不同算力情景下开源模型 0.90 能力前沿的预测

算力情景	预测期	前沿中心值/分	80% 区间	95% 区间
延续趋势 ($\kappa = 1$)	12 个月	65.74	[47.15, 78.37]	[40.25, 86.09]
	24 个月	77.15	[57.30, 90.47]	[47.49, 95.29]
中度放缓 ($\kappa = 0.5$)	12 个月	59.16	[41.91, 69.45]	[36.47, 77.85]
	24 个月	65.74	[47.15, 78.36]	[40.25, 86.08]
强度放缓 ($\kappa = 0.25$)	12 个月	55.72	[39.55, 64.64]	[34.60, 72.52]
	24 个月	59.16	[41.91, 69.44]	[36.47, 77.85]




图 7.8 不同算力情景下 12、24 个月能力前沿预测 (a) 及其在算力—能力前沿上的位置 (b)

7.6 模型检验

滚动回测。在 3 个月与 6 个月步长上各设 4 个有效滚动起点，比较本文模型 (M-C) 与“只有时间” (M-time)、“只有规模” (M-scale) 两种基线 (图 7.9(a))。M-C 相对 M-scale 的平均 pinball 损失差为 0.0012 (配对标准误 0.0012)，未劣化超过一个标准误；M-time 则明显劣于 M-scale (技能分数 -2.08 、 -1.78)。这再次说明**算力是能力前沿的主导解释变量，单纯的时间趋势不能替代它。**

数值验证。全部桥接在稠密 Loss 网络上无单调性违反；问题三的 45 个方案未进入历史前沿训练集；三条分位在中心预测与所有抽样中均保持有序；Shapley 分解在 logit 与得




图 7.9 滚动回测的技能分数 (a) 与能力映射区间宽度的来源分解 (b)

分两个尺度上闭合；相同配置重复运行结果完全一致。全部 30 项检查中 29 项通过，唯一警告为上文所述的 MATH 逐任务复现率不足，已按规则降级处理。

7.7 问题四小结

问题四主要结论

- (1) 以六项官方归一化得分的平均为综合能力，开源口径要求开放权重，贡献分解只用 pretrained 模型，时间轴取提交日期；C8 逐任务重算 BBH 的精确复现率为 97.2%。
- (2) 单调线性 Loss-Benchmark 桥接的留族 MAE 为 10.2 分；问题三的最优方案在 10^{22} 、 10^{24} FLOPs 下对应综合能力约 13.4、19.5 分。映射误差（80% 宽度约 9.2 分）是能力结论的主导不确定性来源，远大于上游 Loss 误差。
- (3) 2024-06 至 2025-01，开源基础模型能力前沿提升 4.62 分，规模扩张贡献约 100%，非规模技术贡献约 0%（区间跨零），结论对口径与样本设定稳健。
- (4) 若算力对数增速保留 100%、50%、25%，24 个月后 0.90 能力前沿中心值分别为 77.2、65.7、59.2 分（80% 区间约 $\pm 12-17$ 分）；算力增速减半，能力前沿的到达时间推迟一倍。

8 模型的评价、改进与推广

8.1 模型的优点

- (1) **广义标度律结构简洁且物理自洽。**以“可约损失 $\times$ 配比因子”的乘性结构统一了参数、数据、质量与配比四个因素： $Q = 1$ 、参考配比时严格退化为经典标度律，任何资源组合下都有 $L > E$ ，并由此严格证明了配比与规模—质量决策的可分性（定理 5.1）。配比效应尺度不变这一关键假设不是凭空设定的，而是在附件 A 的三个数量级规模上得到了检验（ θ 变异系数 0.17）。
- (2) **关键结论有闭式解与严格证明。**质量—规模替代的充要条件、等价增幅与临界规模（定理 5.2），上下文临界长度 $6/\eta$ ，计算最优指数 $N^* \propto C^{0.452}$ ，均为解析结果；数值结果与闭式解相互印证。
- (3) **结构性转移有严格的数学定义。**以 KKT 活跃约束集合的变化定义主要转移、以配置弹性断点定义次要转移，并以参数抽样下的出现概率界定稳定性，使“是否发生质变”成为可以计算、可以检验的问题。
- (4) **验证体系完整，数据使用规范。**每个模型都在未参与训练的数据上检验：配比模型用三个规模的独立检验集，经典标度律用留一规模与跨族数据，质量项用四种方式的成块留出，桥接模型用来源族留一，前沿模型用滚动起点回测。半合成与估算数据只用于补充分析与边界检验。
- (5) **不确定性全链条传播。**从问题一的配比 bootstrap、问题二的参数 bootstrap，到问题三的最优解区间、问题四的桥接与前沿联合抽样，每个关键数值都附有区间，并识别出能力结论的主导误差来源（Loss–Benchmark 映射）。

8.2 模型的不足

- (1) **推断领域的质量无法细分。**质量数据只覆盖 7 个领域，11 个配比领域的质量只能取公共参考值；配比效应本身由实验数据直接估计，因此不影响配比结论，但限制了“质量 $\times$ 配比”交互的刻画。
- (2) **跨体系对齐依赖锚定假设。**问题一与附件 B 的质量尺度以 Q_{ref} 为锚点线性对齐， s_Q 无法由数据唯一识别；敏感性分析显示 s_Q 是影响高预算最优 Loss 的首要因素。
- (3) **高预算结论依赖外推。** 10^{24} FLOPs 的最优规模远超 B1/B7 的观测范围，严格支持域下 Loss 会上升约 0.18；质量成本函数为题设情景，而非实测工程成本。
- (4) **历史面板较短。**确认性前沿只有 7 个月、41 个模型，限制了非规模技术状态的识别能力；Loss–Benchmark 桥接的留族误差约 10 分，能力的绝对水平精度有限。

8.3 模型的改进

- (1) 在同一模型族与验证集上设计 $(N, D, Q, \mathbf{p})$ 的分层因子实验，直接识别质量映射斜率 s_Q 与配比系数 θ ，并检验质量与配比之间是否存在交互。
- (2) 收集语料过滤、去重、合成与审核的实际成本，替代题设质量成本函数；把显存、通信与硬件利用率纳入约束，把单一 FLOPs 约束扩展为多资源约束，并考虑推理成本对最优规模的影响 [40]。
- (3) 对超出支持域的配置采用分布鲁棒优化，在标度律参数的不确定集上优化最坏情况 Loss，以降低外推风险。
- (4) 延长同口径能力面板，加入架构、数据处理、后训练算力等可观测特征，把“非规模技术状态”拆分为可解释的技术通道；引入观测标度律 [29] 的低维能力因子改进 Loss-Benchmark 桥接。

8.4 模型的推广

本文“数据度量—广义标度律—约束优化—能力预测”的框架不依赖特定模型。对视觉、多模态或科学计算基础模型，只需把 Token 替换为图像块、样本或模态单元，重新定义质量指标与序列相关开销，即可沿用同一建模路径。广义标度律的乘性配比结构与可分性定理，可直接用于数据配比实验的设计：先在小模型上确定配比，再把配比迁移到大模型，只需关注规模与质量的分配。在训练管理中，该框架可作为算力预算的规划工具：以中心解给出基准配置，以结构性转移点判断何时应启动质量投入，以外推标签提示决策风险。

参考文献

- [1] Kaplan J, McCandlish S, Henighan T, et al., Scaling Laws for Neural Language Models, arXiv preprint arXiv:2001.08361, 2020.
- [2] Hoffmann J, Borgeaud S, Mensch A, et al., Training Compute-Optimal Large Language Models, *Advances in Neural Information Processing Systems*: volume 35, 30016-30030, 2022.
- [3] Villalobos P, Ho A, Sevilla J, et al., Position: Will We Run Out of Data? Limits of LLM Scaling Based on Human-Generated Data, *Proceedings of the 41st International Conference on Machine Learning*: volume 235, 49523-49544, 2024.
- [4] Muennighoff N, Rush A, Barak B, et al., Scaling Data-Constrained Language Models, *Advances in Neural Information Processing Systems*: volume 36, 2023.
- [5] Asai A, He J, Shao R, et al., Synthesizing Scientific Literature with Retrieval-augmented Language Models, *Nature*, 650:857-863, 2026.
- [6] Gunasekar S, Zhang Y, Aneja J, et al., Textbooks Are All You Need, arXiv preprint arXiv:2306.11644, 2023.
- [7] Scheffé H, Experiments with Mixtures, *Journal of the Royal Statistical Society: Series B (Methodological)*, 20(2):344-360, 1958.
- [8] Cornell J A, Experiments with Mixtures: Designs, Models, and the Analysis of Mixture Data, 3rd ed., New York: Wiley, 2002.
- [9] Wettig A, Gupta A, Malik S, et al., QuRating: Selecting High-Quality Data for Training Language Models, *Proceedings of the 41st International Conference on Machine Learning*: volume 235, 52915-52971, 2024.
- [10] Diakoulaki D, Mavrotas G, Papayannakis L, Determining Objective Weights in Multiple Criteria Problems: The CRITIC Method, *Computers & Operations Research*, 22(7):763-770, 1995.
- [11] Huber P J, Robust Estimation of a Location Parameter, *The Annals of Mathematical Statistics*, 35(1):73-101, 1964.
- [12] Penedo G, Kydlíček H, Ben Allal L, et al., The FineWeb Datasets: Decanting the Web for the Finest Text Data at Scale, *Advances in Neural Information Processing Systems, Datasets and Benchmarks Track*: volume 37, 2024.
- [13] Longpre S, Yauney G, Reif E, et al., A Pretrainer’s Guide to Training Data: Measuring the Effects of Data Age, Domain Coverage, Quality, & Toxicity, *Proceedings of the 2024*

- Conference of the North American Chapter of the Association for Computational Linguistics (NAACL), 3245-3276, 2024.
- [14] Gao L, Biderman S, Black S, et al., The Pile: An 800GB Dataset of Diverse Text for Language Modeling, arXiv preprint arXiv:2101.00027, 2020.
 - [15] Aitchison J, The Statistical Analysis of Compositional Data, Journal of the Royal Statistical Society: Series B (Methodological), 44(2):139-177, 1982.
 - [16] Hoerl A E, Kennard R W, Ridge Regression: Biased Estimation for Nonorthogonal Problems, Technometrics, 12(1):55-67, 1970.
 - [17] Ye J, Liu P, Sun T, et al., Data Mixing Laws: Optimizing Data Mixtures by Predicting Language Modeling Performance, International Conference on Learning Representations (ICLR), 2025.
 - [18] Liu Q, Zheng X, Muennighoff N, et al., RegMix: Data Mixture as Regression for Language Model Pre-training, International Conference on Learning Representations (ICLR), 2025.
 - [19] Besiroglu T, Erdil E, Barnett M, et al., Chinchilla Scaling: A Replication Attempt, arXiv preprint arXiv:2404.10102, 2024.
 - [20] Sorscher B, Geirhos R, Shekhar S, et al., Beyond Neural Scaling Laws: Beating Power Law Scaling via Data Pruning, Advances in Neural Information Processing Systems: volume 35, 2022.
 - [21] Vaswani A, Shazeer N, Parmar N, et al., Attention Is All You Need, Advances in Neural Information Processing Systems: volume 30, 2017.
 - [22] Dao T, Fu D Y, Ermon S, et al., FlashAttention: Fast and Memory-Efficient Exact Attention with IO-Awareness, Advances in Neural Information Processing Systems: volume 35, 2022.
 - [23] Schwarz G, Estimating the Dimension of a Model, The Annals of Statistics, 6(2):461-464, 1978.
 - [24] Fourrier C, Habib N, Lozovskaya A, et al., Open LLM Leaderboard v2, 2024.
 - [25] Hugging Face, Open LLM Leaderboard: Scores Normalization, 2024.
 - [26] Liu H, Xie S M, Li Z, et al., Same Pre-training Loss, Better Downstream: Implicit Bias Matters for Language Models, Proceedings of the 40th International Conference on Machine Learning: volume 202, 22188-22214, 2023.
 - [27] Schaeffer R, Miranda B, Koyejo S, Are Emergent Abilities of Large Language Models a Mirage?, Advances in Neural Information Processing Systems: volume 36, 2023.
 - [28] Du Z, Zeng A, Dong Y, et al., Understanding Emergent Abilities of Language Models from the Loss Perspective, Advances in Neural Information Processing Systems: volume 37, 53138-53167, 2024.

- [29] Ruan Y, Maddison C J, Hashimoto T, Observational Scaling Laws and the Predictability of Language Model Performance, *Advances in Neural Information Processing Systems: volume 37*, 2024.
- [30] Schaeffer R, Schoelkopf H, Miranda B, et al., Why Has Predicting Downstream Capabilities of Frontier AI Models with Scale Remained Elusive?, *Proceedings of the 42nd International Conference on Machine Learning: volume 267*, 53177-53266, 2025.
- [31] Koenker R, Bassett J, Gilbert, Regression Quantiles, *Econometrica*, 46(1):33-50, 1978.
- [32] Hyndman R J, Athanasopoulos G, *Forecasting: Principles and Practice*, 3rd ed., Melbourne, Australia: OTexts, 2021.
- [33] Chernozhukov V, Fernández-Val I, Galichon A, Quantile and Probability Curves Without Crossing, *Econometrica*, 78(3):1093-1125, 2010.
- [34] Shapley L S, A Value for n -Person Games, Kuhn H W, Tucker A W, *Contributions to the Theory of Games II: volume 28*, Princeton University Press, 307-317, 1953.
- [35] Künsch H R, The Jackknife and the Bootstrap for General Stationary Observations, *The Annals of Statistics*, 17(3):1217-1241, 1989.
- [36] Ho A, Besiroglu T, Erdil E, et al., Algorithmic Progress in Language Models, *Advances in Neural Information Processing Systems: volume 37*, 2024.
- [37] Epoch AI, *AI Models Documentation: Estimation*, 2025.
- [38] Sevilla J, Roldán E, Training Compute of Frontier AI Models Grows by 4–5x per Year, 2024.
- [39] Sevilla J, Heim L, Ho A, et al., Compute Trends Across Three Eras of Machine Learning, *2022 International Joint Conference on Neural Networks (IJCNN)*, 1-8, 2022.
- [40] Sardana N, Portes J, Doubov S, et al., Beyond Chinchilla-Optimal: Accounting for Inference in Language Model Scaling Laws, *Proceedings of the 41st International Conference on Machine Learning: volume 235*, 2024.

附录 A AI 工具使用说明

根据赛题《AI 使用规范》第 4 条，本队披露 AI 工具的使用情况如下。本队对全部 AI 输出进行了核验，并对论文的正确性负责；论文中的理论、公式与实验结论均以正式文献或本队程序计算的数据为依据，未以 AI 输出作为学术依据。

表 A.1 AI 工具使用情况

AI 工具	使用环节	贡献范围
Claude Code (Anthropic, Claude Opus 5.5)	论文修改与排版	论文文字润色与章节结构调整；依据本队程序输出的结果文件统一重绘插图配色与版式；核验参考文献的作者、出处与 DOI；对本队已有结果做补充计算与核对（配比效应系数 θ 的跨规模计算、等价增幅闭式解与数值解的一致性核对）
【待补：本队据实补充】	【待补：如：代码调试、资料整理】	【待补：据实填写】

附录 B 支撑材料与程序清单

全部程序均为 Python 3 实现，随机种子固定为 2026，结果可完整复现。各问题的程序、配置与主要结果文件如表 B.1 所示。

表 B.1 支撑材料清单

问题	主要程序	主要结果文件
问题一	problem1.py; src/problem1/ (data_quality.py、mapping.py、mixture.py)	领域质量 quality_domain.csv; 配比检验 mixture_metrics.csv; 近优配比 optimal_mixture.csv
问题二	problem2.py; src/problem2/ (classic.py、quality.py、generalized.py)	广义标度律参数 generalized_scaling_parameters.json; 配比迁移 mixture_transfer_parameters.csv; 等价量 quality_parameter_equivalence.csv
问题三	problem3.py; src/problem3/ (optimize.py、cost.py、transitions.py)	最优配置 optimal_allocations.csv; 预算路径 budget_paths.csv.gz; 转移点 transition_points.csv; 领域 Token 分配 domain_token_allocations.csv
问题四	problem4_v2.py; src/problem4/ (bridge.py、frontier.py、c8.py)	桥接 loss_benchmark_predictions.csv; 贡献分解 contribution_decomposition.csv; 前沿预测 frontier_forecast.csv
绘图	论文图片目录下 paper_style.py、redraw/redraw_p1.py-redraw_p4.py	全文插图 (统一配色, 数据取自各问题 figure_data/)

核心代码：广义标度律与解析降维求解（问题二、三）

```
import numpy as np
E, A, B, alpha, beta = 1.6897976, 0.3539803, 1.2403056, 0.3399766,
0.2798781
cQ, nuQ, theta, Q0 = 0.3620399, 0.9902881, 0.0847, 0.5389560

def loss(N, D, Q, R=0.0, sQ=1.0):
    """广义标度律（问题二）：N、D 为绝对数量，R 为标准化配比响应"""
```

```

n, d = N / 1e9, D / 1e9
Qeff = np.clip(Q0 + sQ * (Q - Q0), 1e-6, 1.0)
core = A * n**(-alpha) + B * d**(-beta) + cQ * (1 - Qeff)**nuQ
return E + core * np.exp(theta * R)

G = {"exp": lambda q: 1e7 * np.exp(6 * q),
      "pow": lambda q: 5e9 * q**4,
      "log": lambda q: 2e9 * np.log1p(10 * q)}

def d_star(N, Q, C, g, Lctx, eta=2e-4):
    """问题三：用尽预算时的最大 Token 数，用于把三维问题降为二维"""
    dg = max(G[g](Q) - G[g](Q0), 0.0)
    return C / ((6 + eta * Lctx) * N + dg)

def equivalent_increase(N, D, Q, dQ):
    """质量—规模替代定理：质量提升 dQ 的等价参数、数据增幅（闭式解）"""
    n, d = N / 1e9, D / 1e9
    delta = cQ * ((1 - Q)**nuQ - (1 - Q - dQ)**nuQ)
    rN = (1 - delta / (A * n**(-alpha)))**(-1 / alpha) - 1 if delta < A *
        n**(-alpha) else np.inf
    rD = (1 - delta / (B * d**(-beta)))**(-1 / beta) - 1 if delta < B *
        d**(-beta) else np.inf
    return rN, rD # N=1e9, D=1.5e11, Q=0.539, dQ=0.1 -> (0.373, 0.569)

```